

分类号_____

学校代码 10487

学号 M201771864

密级_____

华中科技大学

硕士学位论文

基于 GAN 的高压电抗器故障振动信号生成技术研究

学位申请人：陈 鹏 安

学 科 专 业：信息与通信工程

指 导 教 师：陈建文 副教授

答 辩 日 期：2020 年 6 月 2 日

**A Thesis Submitted in Partial Fulfillment of the Requirements
for the Degree of Master of Engineering**

**Research on GAN-based high-voltage reactor fault vibration
signal generation technology**

Candidate : Chen Peng'an

**Major : Information and Communication
Engineering**

Supervisor : Prof. Chen Jianwen

Huazhong University of Science & Technology

Wuhan 430074, P.R.China

June, 2020

独创性声明

本人声明所呈交的学位论文是我个人在导师指导下进行的研究工作及取得的研究成果。尽我所知，除文中已经标明引用的内容外，本论文不包含任何其他个人或集体已经发表或撰写过的研究成果。对本文的研究做出贡献的个人和集体，均已在文中以明确方式标明。本人完全意识到本声明的法律结果由本人承担。

学位论文作者签名：

日期： 年 月 日

学位论文版权使用授权书

本学位论文作者完全了解学校有关保留、使用学位论文的规定，即：学校有权保留并向国家有关部门或机构送交论文的复印件和电子版，允许论文被查阅和借阅。本人授权华中科技大学可以将本学位论文的全部或部分内容编入有关数据库进行检索，可以采用影印、缩印或扫描等复制手段保存和汇编本学位论文。

保密 ☐， 在 _____ 年解密后适用本授权书。
本论文属于 不保密 ☐。

（请在以上方框内打“√”）

学位论文作者签名：

指导教师签名：

日期： 年 月 日

日期： 年 月 日

摘 要

随着社会经济的发展,电力需求容量不断增加,高压电抗器在电网中得到了广泛的应用。以数据为驱动的深度学习在电气设备的故障信号识别应用,克服传统故障信号识别方法的缺陷,对提高电力系统的安全性具有重要的意义。由于高压电抗器的数据价值密度较低,即故障状态下的数据量少,所以利用深度学习对小样本数据进行数据增强,解决了高压电抗器故障信号识别质量不高的问题,成为深度学习在高压电抗器故障信号识别深入研究和发展的关键。

本文为了研究 BKD2-140000/800-110 型电抗器故障振动信号识别,解决故障状态下的数据量少的问题,建立了卷积神经网络故障振动信号识别模型;提出用一维深度卷积生成对抗网络(DCGAN)来生成故障振动信号,实现数据增强;提出用一维卷积神经网络(CNN)来实现对该电抗器的故障振动信号识别。经过实验验证,本文提出方法能够有效解决 BKD2-140000/800-110 型电抗器故障振动信号数据增强和识别的问题。本文主要完成了以下两方面的工作:

1. 提出了用一维 DCGAN 来生成高压电抗器故障振动信号。DCGAN 在实际训练过程中难以收敛,从损失函数角度分析了训练过程存在不稳定性的原因,给出了稳定训练的措施。提出了用一维 CNN 来识别高压电抗器的故障振动信号,完成对电抗器的故障振动信号的识别。仿真实验验证了一维 CNN 能有效识别高压电抗器的故障振动信号,并且一维信号 DCGAN 增强数据的方法,与传统的方法比较,能有效提高高压电抗器的故障识别率。

2. 根据 BKD2-140000/800-110 型电抗器实采故障振动信号数据,利用一维 DCGAN 和一维 CNN 完成该电抗器故障振动信号的生成和识别,提高故障振动信号识别率 3% 左右,提升效果优于传统方法,从而验证了本文提出高压电抗器故障信号生成和识别方法的有效性。

关键字: 生成对抗网络, 卷积神经网络, 故障信号识别, 高压电抗器

ABSTRACT

With the development of social economy, the power demand capacity continues to increase, and high-voltage reactors have been widely used in power grids. The application of data-driven deep learning in fault signal recognition of electrical equipment, to overcome the shortcomings of traditional fault signal recognition methods, is of great significance for improving the safety of power systems. Due to the low data value density of the high-voltage reactor, that is, the amount of data under the fault state is small, so deep learning is used to enhance the data of small sample data, which solves the problem of low-quality fault signal recognition of high-voltage reactors, and becomes the key of deep learning in the deep research and development of fault signal recognition of high-voltage reactors.

In this paper, in order to study the BKD2-140000 / 800-110 reactor fault vibration signal recognition and solve the problem of small data amount under the fault state, a convolution neural network fault vibration signal recognition model is established; a one-dimensional DCGAN is used to generate fault vibration signal to achieve data enhancement; a one-dimensional CNN is proposed to realize fault vibration signal recognition of the reactor. After experimental verification, the method proposed in this paper can effectively solve the problem of BKD2-140000 / 800-110 reactor fault vibration signal data augmentation and recognition. This article mainly completed the following two aspects of work:

1. It is proposed to use one-dimensional DCGAN to generate high-voltage reactor fault vibration signals. DCGAN is difficult to converge in the actual training process. From the perspective of the loss function, the reason for the instability of the training process is analyzed, and measures for stable training are given. It is proposed to use one-dimensional CNN to identify fault vibration signals of high-voltage reactors. Simulation experiments verify that the one-dimensional CNN can effectively identify the fault vibration signal of the high-voltage reactor, and the one-dimensional signal DCGAN enhanced data method, compared with the traditional method, can effectively improve the high-voltage reactor fault recognition rate.

2. According to the BKD2-140000 / 800-110 reactor actual fault vibration signal data,

use one-dimensional DCGAN and one-dimensional CNN to complete the generation and identification of the reactor fault vibration signal, and compared with the traditional method to improve fault vibration signal recognition rate by about 3%, which verifies the effectiveness of the method of generating and identifying the fault signal of the high-voltage reactor proposed in this paper.

Keywords: Generative Adversarial Networks, Convolutional Neural Networks, Fault Signal Recognition, High-voltage Reactor

目 录

摘 要.....	I
ABSTRACT	II
目 录.....	IV
1 绪论.....	1
1.1 研究背景及意义.....	1
1.2 国内外研究现状.....	2
1.3 论文主要工作及章节结构	5
2 卷积神经网络和生成对抗网络原理	7
2.1 卷积神经网络基本原理	7
2.2 生成对抗网络基本原理	13
2.3 本章小结.....	17
3 基于 DCGAN 的故障振动信号生成	18
3.1 电抗器振动信号模型	18
3.2 DCGAN 模型基本原理	20
3.3 电抗器仿真振动信号的生成	29
3.4 基于 CNN 的仿真故障振动信号识别	36
3.5 本章小结.....	41
4 BKD2-140000/800-110 型高压电抗器故障振动信号生成与识别.....	43
4.1 实验平台及数据集	43
4.2 一维 DCGAN 和一维 CNN 网络设计.....	45
4.3 实验结果与分析.....	47
4.4 本章小结.....	51

华中科技大学硕士学位论文

5 总结与展望	53
致 谢.....	55
参考文献.....	56

1 绪论

1.1 研究背景及意义

随着中国经济的发展,电力需求容量不断的提升,电力系统中电抗器的应用也随之日益广泛^{[1][2]}。主要有以下应用:在电网中并联电抗器进行无功补偿,改善电力系统的电压分布;在短路电流过高的线路中串联电抗器来抑制短路电流,提高断路器的开断能力;由电抗器组成滤波装置来抑制电网中的高次谐波^[3-5]。

电抗器分类方式有很多,其中根据其功能可以划分为:串联电抗器、并联电抗器、限流电抗器、分裂电抗器等;根据冷却方式划分电抗器可分为油浸式电抗器和干式电抗器;根据结构型式不同来进行划分,电抗器可分为铁心电抗器和空心电抗器^[6]。目前高压并联电抗器主要采用干式空心并联电抗器和油浸式并联电抗器两种。干式空心电抗器结构简单,无绝缘油,价格低廉,因此在国内的应用非常广泛;另一方面,干式空心并联电抗器也存在着很大的缺点,例如占地面积大,漏磁较大,绝缘受环境影响大且易发生绝缘老化,易发生故障,缺少有效的运行监控手段等^[7]。油浸式铁心电抗器虽然造价比干式空心并联电抗器高,但因为同变压器一样具有外壳,是在封闭环境中运行,绝缘不受外界影响,稳定性高,不易发生故障,占地少和漏磁小,可以通过油化分析、压力监测等方法对电抗器进行监控,因此逐渐显示出较大的优势^{[8][9]}。

根据大量的实践和研究表明,电抗器的主要故障是由于内部局部放电、局部过热及设备绝缘的老化等潜伏性故障随着时间积累引起的。目前,电抗器保护方法主要通过故障时的电压、电流、功率因数等电气指标进行继电保护。然而,电抗器的各种潜伏性故障缺少有效的检测方法和相关技术。传统的电气指标检测方法需要在电气线路中接入相应的传感器,且要在工作状态下进行测量。这种侵入式的测量方法既增加了测量的复杂度,而且在带电测量过程中也存在着安全隐患。因此,利用传统的电气指标检测和诊断方案仍然存在一定的局限性,还需要加以修改以满足越来越高的安全性需求。

近年来,人工智能、深度学习等概念在能源、金融、互联网等领域大放异彩,以大量数据为驱动,能有效的解决分类、预测等问题。当下,智能电网概念发展得如火如荼,收集了大量电力系统数据,利用神经网络完成对于电抗器等电气设备的故障诊断为人们解决相关问题提供了一个新的思路,对克服电抗器故障监测的障碍和提高电力系统的安全性具有重大的价值。同时,由于电力系统的信息价值密度较低,即故障状态下的数据很少,所以利用深度学习对小样本数据进行数据增强,解决了电网大数据质量不高的问题,成为机器学习在电力领域深入研究和发展的关键。

1.2 国内外研究现状

电抗器的故障可以分为两大类,突发性故障和潜伏性故障。突发性故障发展很快,瞬间后果严重,如雷击等,一般可以通过继电保护装置进行保护。潜伏性故障一般分为3种,即电抗器内部局部放电、局部过热和电抗器的绝缘受潮与老化等。目前对于电抗器检测的参量主要有:

- 1) 绝缘水平相关测量;
- 2) 温度检测;
- 3) 振动检测。

1.2.1 传统的检测方法

(1) 绝缘水平相关测量

电抗器的故障也可分为电气与非电气两类,电器类故障往往是由于绝缘水平的劣化引起的,如电抗器的绕组匝间短路等^[10]。为了避免电抗器发生严重的电气故障,它的绝缘水平的检测参量是电抗器潜伏性故障检测参量中重要的一部分,如对电抗器的绝缘电阻、吸收比、极化指数、介质损耗因数 $\tan \delta$ 、泄漏电流、绝缘油色谱、气体成分比等的检测^[11]。

顾哲屹参考干式空心电抗器的制造工艺,设计了类电抗器结构的实验平台,在两种加压方式下测量电老化试验(起始放电电压和绝缘电阻)数据并进行统计分析,表

明了起始放电电压与绝缘电阻和电抗器匝间损伤有较强相关性^[12]。

在匝间绝缘破损短路导致的电抗器故障中，初期各项电气参数变化并不明显，一般采用远红外温度监测方法，但该方法也受到环境温度、监测点位置等因素的制约。文献[13-16]提出了基于介质损耗因数的电抗器故障在线监测手段，利用电抗器的等值电路模型，计算线圈之间形成的短路环在正常和异常工作状态下的等效电阻、介质损耗因数等参量，发现在发生匝间短路的时候，所有监测指标中介质损耗因数的数值变化是最大的。由此证明，介质损耗因数可以作为判断电抗器工作状态的一个重要依据。

电抗器处于异常工作状态时会产生局部温度升高一级局部放电的现象，而此时油浸式电抗器中的绝缘油（来自石油的提取物）就会在上述现象的作用下发生裂解，产生烃类气体（甲烷、乙烷、乙烯、乙炔）、氢气等，并溶解于绝缘油中。可以通过测量绝缘油中 C_2H_4/C_2H_6 、 CH_4/H_2 、 C_2H_2/C_2H_4 这三个气体含量的比值来对电抗器故障状态做出较为可靠的诊断，称为三比值法^[17-19]。田肖飞等人对 W41 号电抗器油中气体进行分析，发现乙炔含量过高，经过吊罩检查之后发现铁心（及夹件）存在着接地不可靠现象^[20]。孙帆等人对某 750kV 变电站高压并联电抗器进行诊断，分析乙炔和氢气体积分数增长过快，通过采取局部放电定位、振动检测、高亢温升试验等手段，确定了电抗器铁心固定结构设计不佳是导致故障出现的原因^[21]。

(2) 温度检测

电抗器属于变压器类电力设备，也存在漏磁现象。磁漏通在绕组中形成环流，匝间短路也会有环流产生，加剧了器械的发热，会引起电抗器的局部过热，对工作状态和设备安全产生重大影响。此外，局部温度过高会导致线圈外绝缘层破损，铁心和绕组的变形等^{[22][23]}。戴奇奇通过有限元的分析方法，建立电抗器电路-磁场耦合计算模型，计算电抗器内部的温度分布和绝缘油流速的分布，发现电抗器从上到下整体温度呈现由高到低的变化趋势，并且绝缘油流速也不相同。整体速度较低，但是底部流速慢与中部与顶部，内径与外径表面流速比线圈横向油道流速快。通过对流速的研究表明了电抗器内部温度分布不均衡的原因^[24]。Yuan F T, Cao J 和 Hongyan N 等人利用

磁场-温度场耦合的方式建模, 基于有限元法对线圈绕组周围的温度场和磁场进行计算, 模拟实际环境中的绕组包封壁面与外部空间对流热交换过程, 由于该方法不依赖于对流换热系数的选择, 鲁棒性更强, 计算精度相对较高^[25-28]。Yu Jiaozhang 等人^[29]在此磁场-温度耦合场的基础上加入了对星型架的分析, 建立了完整度更高的电抗器温度分布模型, 提升了耦合场分析方法的准确性^[29]。张琪在原有基于温度的电抗器在线监测研究的基础上, 为了避免使用平均温升法导致只能计算平均温度而无法测量电抗器局部温度变化的局限, 提出了基于损耗因数的在线监测方法。其研究发现, 随着温度的升高, 损耗因数变化速度减小, 且并联电抗器与串联电抗器匝间短路时电气指标随温度变化趋势一致。单纯的根据温度场变化可能会产生误诊现象, 但是通过其他电气参数辅助温度场的观测, 提高了诊断的准确率^[30]。

(3) 振动检测

近年来, 随着电网电压等级的不断提高和对其安全性要求的不断增强, 非侵入式的振动检测成为了大家研究关注的热门课题之一。电抗器的振动与其机械结构有着密不可分的关系, 产生振动主要有两方面的原因: 一是铁心本身在其产生的磁场中受力伸缩产生的振动; 二是因为铁心饼彼此之间的麦克斯韦力引起气隙垫块振动, 进而导致整个铁心饼发生振动。电抗器出现故障的时候, 相应地其电磁场的结构与分布也会发生变化, 从而对振动信号产生影响, 如电抗器在故障时由于异常振动可能会导致其金属波纹管疲劳破裂从而引起漏油的现象。Song Meng 等人提出了一种电抗器磁致伸缩的简化模型, 并在此基础上分析了电抗器在不同铁心材料、铁心结构和绕组安装条件下的振动情况, 取得了大量研究成果^[31]。文献[32]针对电网中实际运行且发现异常情形的电抗器进行故障诊断, 在油箱外壳上加装振动位移、速度和加速度传感器来实时监测电抗器运行过程中的振动情况。对振动监测结果进行分析, 随后对每个速度和加速度传感器进行加窗傅里叶变换, 发现一个非铁心振动的振源, 经过定位显示该异常振源位于 X 柱靠接地引下线侧。对电抗器进行吊罩检查, 果然在 X 柱芯柱地屏的 34 和 35 号铜带上发现明显的黑色放电痕迹。潘信诚等根据电抗器油箱表面的振动信号来判断电抗器铁心和绕组的状态, 并提出一种基于递归量化分析 (RQA) 和交叉递归图 (CRP) 的融合信号分析处理方式^[33]。该方法能够定性地描述不同观测点

振动信号的相关性，还可通过计算 RQA 指标进行定量描述，为振动传感器的位置选取提供了重要参考。

1.2.2 基于机器学习的检测方法

由于不需要过于深入的专业知识和业内经验，同时避免了复杂的物理建模过程，基于机器学习的电抗器故障检测方法越来越引起人们的关注。前文介绍的各种电抗器检测参量均可作为训练数据交由神经网络学习，并最终给出一个非常良好的诊断准确率。赵文清、王强等人将绝缘油中溶解气体成分作为属性变量，利用朴素贝叶斯网络，建立 5 级电抗器健康状态诊断法，参考了实验测试电抗器的历史状态及当前状态，预测了其未来的状态^[34]。Richardson Z J 等人以多维油中溶解气体成分比值为特征，输入 Parzen 窗分类器，对油浸式电抗器设备进行诊断^[35]。吴金利、马宏忠等人首先通过分析高压并联电抗器表面振动信号的频域和幅度特性，将振动信号的分段功率谱和主成分系数等参量作为特征向量，利用神经网络、SVM、KNN 等机器学习算法进行故障诊断，并成功开发出一套基于多种机器学习算法的电抗器故障在线监测系统^[36]。干式空心电抗器经常由于匝间短路，形成很小的电弧，最后合并变大成树枝状放电，这一现象称为局放。赵春明等人利用超高频传感器接受局放瞬间辐射产生的超高频电磁波，对 BP 神经网络进行改进，将正常和故障状态下的电磁场数据送入到循环神经网络中进行训练，最后通过理论分析和试验证明了 ANN 对干式空心电抗器局部放电检测的有效性^[37]。

1.3 论文主要工作及章节结构

本文针对高压电抗器的故障信号识别做了较为详细的总结，提出一种基于一维 CNN，以振动信号为特征参量的电抗器故障振动信号识别模型。并且，由于在深度学习中，尤其是分类和识别问题，需要以大量数据为驱动，才能更好地训练网络参数，避免因数据量过少出现过拟合现象。为了解决电抗器故障信号识别模型中的数据增强问题，提出了一种针对一维振动信号的 GAN 生成模型，并最终以 BKD2-

华中科技大学硕士学位论文

140000/800-110 电抗器振动信号数据为数据集，通过实验验证了 CNN 识别故障振动信号和 GAN 生成故障振动信号方法的有效性。论文的主要章节安排如下：

第一章“绪论”，说明了本文的研究背景及意义，对现有的电抗器故障诊断方法做了一个较为详细的综述，并引出了用于分类网络的数据量不足问题。

第二章“卷积神经网络和生成对抗网络原理”，阐明了用以生成数据的 GAN 和用以故障识别的 CNN 的基本原理和结构特性。

第三章“基于 DCGAN 的故障振动信号生成”，设计了具体的 DCGAN 模型，分析了 DCGAN 模型在训练中存在不稳定现象的原因并给出稳定训练的措施。最后以故障振动仿真信号为实例进行试验，证明了该方法的有效性和可行性。另外，介绍了在电抗器故障诊断问题中 CNN 模型的具体设计，将振动仿真信号作为训练集，验证了 CNN 在电抗器故障振动识别问题上的可行性。

第四章“BKD2-140000/800-110 型高压电抗器故障振动信号生成与识别”，以 BKD2-140000/800-110 型电抗器的实采数据来设计实验，不仅在 CNN 中得到了较高的识别率，而且加入 DCGAN 模型生成数据的实验数据提升了 CNN 的识别准确率。除此之外，还探究了 GAN 数据增强方法的适用数据规模范围，并与其他数据增强算法作比较，实验证明了 GAN 在数据生成方面更胜一筹。

第五章“总结与展望”，总结了全文所做的工作，并指出了不足之处，为未来的研究方向给出了一定的思路。

2 卷积神经网络和生成对抗网络原理

人工神经网络（Artificial Neural Network, ANN）是人们受到生物学中神经系统的基本原理的启发，模仿生物神经元之间的电信号传递方式，以网络拓扑知识为理论基础，模拟人脑对于复杂环境下信息处理机制的一种数学模型。这种模型实际上是由大量简单且重复的子单元组合而成的复杂网络结构，具有高容错性、自适应学习能力和非线性等特点。由于这些特性，ANN 目前已被广泛应用于语音、文字、图像等的处理。用于输入人工神经网络的数据称为训练数据，输入到网络中后，由网络自发地学习输出数据与输出结果之间的映射关系，并自适应地调整网络中的各个参数，最后利用学习到的这种规律对新的输入数据进行预测并输出结果，这一个网络学习规律和分析的过程被称之为训练。其他网络模型均是在人工神经网络的基础上发展而来，多通过误差反向传播来训练，参数更新一般采用梯度下降法。下面本文对卷积神经网络和生成对抗网络的基本原理进行介绍。

2.1 卷积神经网络基本原理

卷积神经网络CNN（Convolutional Neural Networks）如字面意义所示，即在神经网络中加入了做卷积运算的算子，这个卷积算子在神经网络中一般被称为卷积核或者滤波器。卷积神经网络通过卷积核的局部感受，提取图像信息的特征，网络结构越复杂，深度越深，能够提取到更为深层次的信息。利用提取到的特征可以更好地完成目标检测或者预测等任务，提升分类任务的准确率。卷积神经网络与传统机器学习算法相比，不需要人为先提取特征信息，再构建特征向量，可以交由神经网络自己去寻找所需处理数据背后潜在的特征和数学规律。

2.1.1 卷积神经网络的特性

卷积神经网络有两个基本的特性，其中第一个特性就是局部感受野^[38]。在一般的神经网络中，一个像素点会连接到全连接层的每一个神经元上，而卷积神经网络只是

把隐藏层的每个节点连接到原图片的一部分区域上，这样非卷积的神经网络产生的连接数是远远多于卷积神经网络的连接数的。例如在对于一 $1024*720$ 像素大小的图片的识别问题中，一般来说是把图片当作一个 $1024*720$ 大小的矩阵输入到神经网络中。假设输入的全连接层的神经元数目和该图片的像素点数目一样多，则从输入层到全连接层的总连接数将达到 10^{12} 数量级，连接数之庞大，参数之多，对于计算机的运算过程产生了巨大的负荷，会导致训练过程十分漫长，可能会出现内存溢出，无法训练的问题。若采用 $9*9$ 的感受野与上述大小的图片做卷积操作，则只需要81个权值参数，极大地减少了参数数量，便于计算机的运算。

联想到人类观察事物的角度，一般是从局部出发，逐渐窥至全身。对于图像处理而言也是如此，物理距离上相靠近的像素点之间的关联性很高，联系更加紧密，而相距比较远的像素点之间差异很大，没有什么太大的关联。因此在图像处理等问题中，可以采用卷积核来对一个区域进行感知和特征提取，而不用对图像中的每一个像素点做处理。图2.1和2.2分别给出了神经元之间全连接和局部链接的示意图，方便大家理解。如图2.1所示，在全连接的情况下，每一层的神经元都与上一层所有的神经元相连，如 o_2 与 i_1 、 i_2 、 i_3 、 i_4 、 i_5 相连，由矩阵运算可知，总共需要有 $5 \times 5 = 25$ 个权重参数。但是在图2.2中，神经元之间并非采用的全连接方式，而是使用局部连接方式，如 o_2 仅与 i_1 、 i_2 、 i_3 相连。在这种使用卷积核大小为3的局部连接模式中，总共需要有 $5 \times 3 = 15$ 个权重参数，与全连接模式相比，减少了40%的参数数量。局部连接方式大大地减少了权重参数的数量，缩短了神经网络训练时间，减轻了计算机的运算负荷，在一定程度上避免了训练过程中出现的过拟合现象。




图2.1 全连接模型示意图




图2.2 局部连接模型示意图

卷积神经网络的另一大基本特性就是权值共享^[39]。在卷积神经网络中，使用一定大小的卷积核与图片进行大量的卷积操作，能够提取出图片中的某些特征。若使用一个卷积核，则卷积运算过程就可以提取出一张图片中不同区域处的同一个特征，若想要在一张图片中提取不同的特征，则需要使用多个卷积核。因此，卷积网络对于图像小范围内的处理具有较好的平移不变性，例如平移一张图片中的某个对象后，仍可以使用卷积神经网络将其识别出来。权值共享即使用相同的卷积核对图片进行处理，权值参数的数目就是卷积核的大小。由于权值共享，神经元对应位置的权重值相同，进一步减少了网络的参数量。以图2.2中的具体连接模型为例，采用了权值共享后，原本需要15个参数量的局部连接，现在只需要3个参数，减少了80%的参数量。权值共享特性实质上进一步缩减了网络需要训练的参数总量，不像传统的神经网络，权重矩阵中的每一个权重参数在一层输出的计算中只能被使用一次，而卷积网络中同一个

权重参数可以被输入矩阵中的元素多次使用。

2.1.2 卷积神经网络的基础结构

一般地，一个卷积神经网络至少含有全连接层、池化层、卷积层等子结构，所有层次组合在一起完成对于一张图像中的特征提取^[40]。通常在训练过程中，图像首先经过一个卷积层，通过卷积层来提取图片中所要寻找的特征，图片做卷积运算后提取出来的特征就叫做特征图，上一层输入的特征图再经过卷积运算之后又可以得到新的特征图。有时候因为图片的像素点太多，可能会影响训练的效率，需在卷积层之后再接入一个池化层，起到下采样的作用，减少网络中的参数量。全连接层又称为仿射层，一般接在多个卷积层和池化层之后，用以做维度之间的转换。最后，如果是二分类器的话连接一个Sigmoid函数，多分类器则接上一个Softmax函数，输出分类概率向量。

Yann LeCun于1998年提出了一个经典的卷积神经网络模型，LeNet-5模型^[41]。LeNet-5模型的基本结构如图2.3所示。该网络被设计用来完成手写体数字识别，可以借助这一网络对卷积神经网络的基本组成结构有一个直观的认识。




图2.3 LeNet-5网络结构示意图

从图2.3中可以看出，LeNet-5网络总共包含了C1、S2、C3、S4、C5、F6和OUTPUT总共七层结构。其中，C1、C3、C5为卷积层，S2、S4为池化层（下采样层），F6为全连接层，OUTPUT层是选用了Softmax激活函数的十分类输出。下面分别对卷积层、池化层和全连接层进行介绍。

(1) 卷积层

在卷积神经网络中，卷积层无疑是最为关键的一个组成成分，进行卷积操作来提取图像特征。在进行卷积运算时，卷积核（或称过滤器）与图片重叠，从图片左上角开始，卷积核权重与图片对应位置处的像素值做矩阵乘法，对应相乘并相加。做完运算后，卷积核从左往右，从上往下滑动，滑动的距离称之为步长stride。卷积核在滑动一个步长之后，再次进行卷积运算，如此重复，直至图像所有的位置都参与了卷积，此时得到一个特征图。卷积运算的过程可见图2.4所示。一个 3×3 大小的卷积核在一个 5×5 大小的图片上做卷积运算，第一次计算结果为3，之后向右向下分别滑动1的距离，计算9次后最终得到一个 3×3 大小的特征图。做卷积操作之后，图片的大小不断缩减，在深层次的网络中可能会缩减至1个像素。同时相较于图片中间的点，边缘部分的点参与计算的次数比较少，不利于提取边缘位置的信息。因此，可以通过设置padding参数，为原图片四周添加一圈元素（0或1），将原图片变大。这样，原图片的边缘参与计算的次数也会增多。卷积层的数目往往不止一个，因为一个卷积层只能学习到局部的特征，更为深层次的网络更易学习到全局性的特征。




图2.4 卷积运算示意图

(2) 池化层

池化层的主要作用是压缩图像，所以也被称为下采样层。训练神经网络时往往因为图片尺寸较大或者卷积层较多提取的特征维度较高，训练的参数数量很庞大，导致训练时间漫长且容易出现过拟合。在网络中加入池化层，可以起到去除冗余信息，保留主要特征，压缩图像尺寸，降低特征维度的作用。即使图像中的物体发生了平移、旋转、尺度上的变化，但是池化之后仍能保留其中的主体特征，具有不变性的特点。池

化层的核心思想是用局部范围内的主体特征来描述全局范围，与卷积操作类似，同样具有过滤器和步长，但是两者的具体计算方式不同。池化方式主要有最大值池化（MaxPooling）和均值池化（AvgPooling）。最大值池化是在过滤器和图片对应的范围内选取图片中像素的最大值，而均值池化是在过滤器和图片对应区域内取像素的平均值，如图2.5所示。




图2.5 最大值池化和均值池化运算示意图

(3) 全连接层

全连接层一般放在多个卷积层和池化层之后，与Softmax函数或Sigmoid函数组合置于整个神经网络的最末端，将前面提取到的局部特征综合起来，用于输出概率向量。全连接层中的每一个神经元都与上一层的各神经元连接，产生了巨大的参数量，导致训练时间特别漫长，还可能产生过拟合。除此之外，该结构还起到了转换输入输出维度的作用。神经网络中全连接层的输出和输出之间是一个矩阵运算，可表示为式（2-1）：

$$Y = Wx^T + b \quad (2-1)$$

其中， W 表示全连接层的各神经元权重， x 输入全连接层的向量， b 表示偏置量， Y 表示经过全连接层后的输出。

2.2 生成对抗网络基本原理

2.2.1 生成对抗网络概述

2014年, Goodfellow提出了一种具有充分想象力和开拓性的新型神经网络模型——生成式对抗网络GAN (Generative Adversarial Networks) [42]。区别于其他神经网络的单一性和封闭性, GAN模型事实上是由两个神经网络模型嵌套组合而成的。近年来, 针对GAN模型的研究快速发展, 模型本身也产生了非常多的变体, 例如WGAN[43]、BEGAN[44]、CGAN[45]、DCGAN[46]等模型。GAN模型除了被用于图像生成之外, 还被广泛地应用于其他的研究领域, 如用于进行图片风格迁移的CycleGAN[47], 完全无监督条件下可以学习的infoGAN[48], 能够根据低分辨率图像恢复生成极高分辨率图像的SRGAN[49]等等。GAN模型在数据生成方面与传统的数据生成方法有比较大的区别, 传统数据生成方法多采用插值、多项式拟合采样等方案, 而GAN模型采用更为复杂的神经网络进行对抗博弈, 逐渐从离散随机的高斯分布学习到训练样本的数据分布, 由训练样本的更高维度特征中得到我们所需要的数据。这一方法生成的数据中的一个非常突出的特征是, 生成的数据完全不同于训练数据中的任何一组数据, 极大地满足了生成数据的多样性, 进而能为分类识别网络提供更多的数据特征。但是, 最原始的GAN模型还存在着一系列的问题, 例如训练过程困难, 难以收敛; 训练轮次过多时可能出现“模式崩塌”现象, 即生成的对象大量重复相似; 生成的数据质量较低等问题。DCGAN模型在原始GAN模型的基础上做出了一定的改进, 能够很好地从训练集中学习到真实数据的分布, 并生成具有较高质量的新数据。DCGAN在数据生成方面具有的优势, 使得如何利用该网络在各种具体应用环境中生成高质量的数据成为后续研究的重点。

2.2.2 生成对抗网络基本结构

GAN模型的示意图如图2.6所示。图中 $z \sim P_z(z)$ 表示输入生成网络G中的随机噪声,

是一个服从高斯分布的随机变量； $x \sim P_{data}(x)$ 表示输入判别网络D中的真实数据。该网络模型主要分为生成网络G和判别网络D两部分，生成网络G接受输入的高斯噪声 z ，经过各层处理之后生成数据 $G(z)$ ，并将 $G(z)$ 和真实数据分布 x 送入到判别网络D中进行判决， x 判别为真（即为“1”）， $G(z)$ 判别为假（即为“0”），并把判决结果反馈到生成网络G和判别网络D中，指导这两个网络的训练。判别网络D输入一个数据 m ，输出 $D(m)$ 表示判别网络认为 x 为真实数据的概率。经过充分的训练，判别网络D无法很好地区分数据来源是真实的数据还是生成网络G生成的假数据，即 $D(G(z)) = 0.5$ ，而此时经过生成网络G生成的数据分布就能很好地拟合真实数据 X 的分布，也就达成了生成类真实数据，扩充数据集的目标。

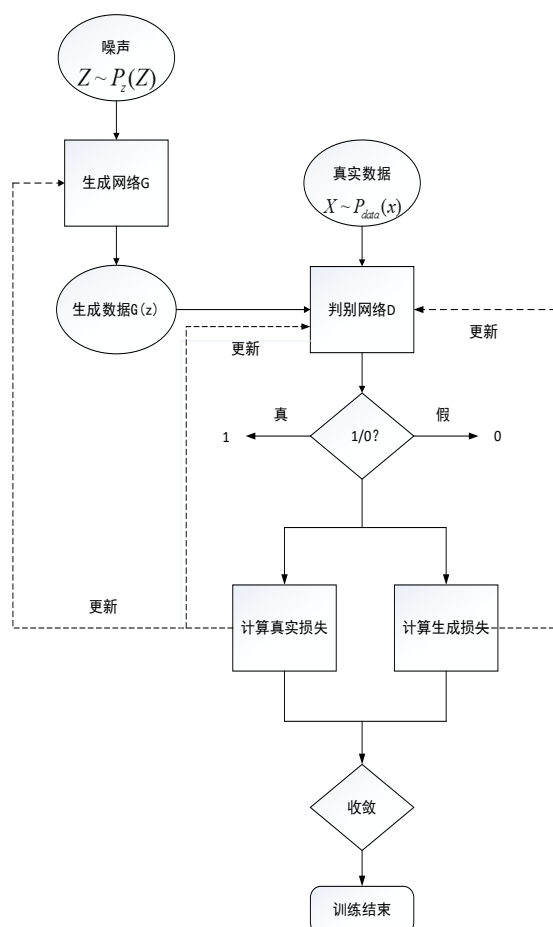


图2.6 DCGAN网络模型示意图

华中科技大学硕士学位论文

GAN核心思想来源于二人零和博弈问题，即两者参与博弈，一个收益增加，则另一者收益必定减少，博弈双方收益之和为一个常数，最终如能达到一个平衡状态，则称为纳什均衡^[50]。GAN网络的生成模型和对抗模型的训练过程，本质上是一个“二元极小极大博弈”问题，训练的目标函数可以表示为公式（2-2）所示：

$$\min_G \max_D V(D, G) = E_{x \sim P_{data}(x)}[\log D(x)] + E_{z \sim P_z(z)}[\log(1 - D(G(z)))] \quad (2-2)$$

式中： x 表示用于训练的真实数据样本， $P_{data}(x)$ 表示真实数据的分布， z 表示输入生成网络的噪声， $P_z(z)$ 表示输入噪声服从的分布， $D(x)$ 表示判别网络将输入该网络的数据被判决为真的概率， $G(z)$ 表示输入噪声经过生成网络后输出的数据。

在模型的训练过程中，由于两个网络是二元博弈的，所以训练过程也是以两个目标为导向。判别模型的训练目标是能够尽量最大化自己准确判断输入信号真实性的概率，当输入的训练数据标签为1（真）时，输出判决结果为1，输入的训练数据标签为0（假）时，输出的判决结果为0，也即使 $D(x)$ 的输出结果无限地逼近1， $D(G(z))$ 的输出结果无限地逼近0。此时， $V(D, G)$ 逐渐变大，也就是求出了 $\max_D V(D, G)$ 。生成模型的训练目标是能够生成尽可能靠近真实数据分布的“假”数据，最小化判别模型正确判断输入信号真实性的准确率，即使 $D(G(z))$ 的输出结果无限地逼近1，也就是求解 $\min_G V(D, G)$ 。在理想的状态下，经过充分地训练之后，输入的已知分布 $P_z(z)$ 的变量噪声 z 将被映射到未知的真实数据分布 $P_{data}(x)$ 的变量 x 之上。由于要对同一个二元目标函数求解最大最小值，在实际的训练过程中，GAN的生成网络G和判别网络D是交替进行优化的，即首先固定生成网络G，来提升判别网络D判断输入数据真实性的准确率。然后，固定判别网络D，优化生成网络G，使其生成更加接近真实数据的结果，尽可能降低判别网络的判断准确率。

由于GAN实际是由两个神经网络模型拼接而成，所以与一般的神经网络模型不同，根据公式（2-2）可知，其总共包含了两个损失，一个是判别网络的损失，一个是生成网络的损失。因为GAN网络本质上是一个二人博弈问题，所以在训练过程中，

不仅要降低两个网络的loss，而且要使两者达到平衡。一般地，按一定规则减小损失函数数值，对其进行优化的算法称为优化算法，通常采用梯度下降优化算法。在训练过程中，对保持两个网络损失函数相对平衡的方法称为优化策略。因此，在对生成对抗网络的生成数据的效果进行评估时，不仅可以使肉眼对生成数据（如图像）进行主观估计，也可以通过观察loss曲线的变化趋势，动态观察GAN的训练过程。

式(2-2)给出了根据GAN定义得到的网络总的交叉熵损失函数。其中期望 $E_{x \sim P_{data}(x)}$ 、 $E_{z \sim P_z(z)}$ 可按照式（2-3）计算。

$$\min_G \max_D V(D, G) = \int P_{data}(x) \log D(x) dx + \int P_z(z) \log(1 - D(G(z))) dz \quad (2-3)$$

GAN 网络是判别网络和生成网络交替进行优化的，所以其目标函数也是分别对两个网络进行优化。首先固定生成网络，对判别网络优化，如式（2-4）所示：

$$\max_D V(D, G) = E_{x \sim P_{data}(x)} [\log D(x)] + E_{z \sim P_z(z)} [\log(1 - D(G(z)))] \quad (2-4)$$

式中， $D(x)$ 表示判别网络对真实数据判断为真的概率。在理想状态下，判别网络的终极目标就是能够完全区分数据是来源于真实的数据还是由生成网络生成的数据。所以，在上式中希望 $D(x)$ 的输出结果能尽可能的接近于1，此时 $\log D(x)$ 的值是最大的。 z 是输入网络的随机噪声， $G(z)$ 是产生的数据。同理，希望判别网络能够使判决结果 $D(G(z))$ 的值尽可能的接近于0，此时 $\log(1 - D(G(z)))$ 能够取得最大值。综合来看，对于判别网络的训练过程就是一个求解函数式最大化的问题。

通常来说，对于神经网络的训练采用梯度下降优化算法比较多。所以，式（2-4）又可以写成如式（2-5）所示形式：

$$\min_G V(D, G) = E_{x \sim P_{data}(x)} [-\log D(x)] + E_{z \sim P_z(z)} [-\log(1 - D(G(z)))] \quad (2-5)$$

在判别网络完成优化之后，固定判别网络，生成网络则可以按照式（2-6）为目标对自身进行优化。在此优化过程之中，生成网络希望各参数朝着 $D(G(z))$ 趋近于 0 的方向更新。这样，目标函数 $V(D, G)$ 整体能够达到一个最小值。

$$\min_G V(D, G) = E_{z \sim P_z(z)} [\log(1 - D(G(z)))] \quad (2-6)$$

2.3 本章小结

在本章中, 主要介绍了由人工神经网络发展而来的生成对抗网络和卷积神经网络的相关理论。生成对抗网络的核心思想是“二元博弈”, 一个生成网络负责生成满足我们需求的数据, 另外一个判别网络负责对生成的数据和真实数据进行判断, 并根据判别结果重新指导生成网络的训练。卷积神经网络最关键的是其特征提取能力, 通过卷积操作来完成。本章介绍了这两个网络的特性和基本组成结构, 为后面章节利用GAN和CNN完成电抗器振动数据的生成和基于电抗器振动数据的故障识别奠定了理论基础。

3 基于 DCGAN 的故障振动信号生成

原始的GAN模型多采用ReLU函数作为各层之间的激活函数，并使用转置卷积网络或者全连接层来提取训练数据的特征。但是，最初的GAN模型在训练过程中存在着难以收敛、生成数据质量不高等问题。为了克服这些已有的缺陷，把已在图像的分类识别任务中展现出出色性能的CNN引入到GAN模型中，利用多个卷积层可以提取图像中复杂纹理特征的特性，迁移到GAN模型中用以提取原始样本的一些高维度特征，稳定训练过程，提升生成数据的质量。因此，受到图像生成问题的启发，本章将多用于图像生成的DCGAN用以解决一维数据的生成问题，并为适应一维数据的特点，把二维卷积层替换为一维的卷积层，在每个卷积层之后加入批归一化层，激活函数替换为LeaklyReLU函数，最终生成了质量较高，与原始数据更为接近的数据，实现了扩充电抗器故障振动信号的目的。针对振动仿真信号，设计了一维CNN模型，完成对故障振动信号的识别。

3.1 电抗器振动信号模型

电抗器在工作状态下会产生周期性的振动，这一现象是由两方面的原因引起的。一方面工作电流流过电抗器铁芯中的硅钢片时，由于硅钢片导磁性能很好，会在硅钢片上出现磁致收缩现象。在与磁场方向相同的方向上，硅钢片会出现延展，在与磁场方向垂直的方向上，硅钢片产生收缩^[51]。另一方面，因为电抗器中铁芯硅钢片与硅钢片间填充的间隙材料的导磁率不同，铁芯饼在磁场作用下产生的麦克斯韦力引起气隙垫块振动，进而引起整个电抗器的振动^[52]。一般地，工作频率为50Hz，在一个周期内，磁场的方向变化了两次，所以电抗器振动的主频率为100Hz。

原始的电抗器振动信号中包含的频率成分很多，也受到了很多其他外界的干扰，信息密度非常低，若想要直接利用该振动信号存在着一定的困难。不加处理地使用原始数据建立基于振动信号的电抗器故障识别模型的话，可能会导致分类准确率不高的问题。因此，本文首先根据频谱特点对振动信号进行建模，使用仿真信号进行进一步的分析与研究，也为后续使用实采振动信号进行分析奠定基础。

华中科技大学硕士学位论文

电抗器油箱表面装有多传感器，由于传感器安装位置的不同，接收到的振动信号不同，信号中包含的频率信息也存在着差异。由于不同传感器的频谱存在着较为明显的差异，无法直接对所有传感器的全频谱进行分析。魏旭，吴书煜等人的研究表明，电抗器振动信号以100Hz频率信号为主，同时还伴有100Hz的倍频信号^[53]。魏旭等人的研究中还指出，振动信号主要集中在低频部分，因此本文主要针对0-1kHz范围内的频谱进行建模。

文献[54]对振动传感器接受信号进行分析，计算电抗器油箱表面9个传感器在0-1kHz范围内的频谱，以100Hz为标准将其他100Hz整数倍的频率点的频域幅值归一化，取9个传感器的幅值平均值计算并保存下来。经对比，正常工作状态电抗器和异常工作状态的电抗器在0-1kHz频率范围内的10个频率点的平均幅值有着较为明显的差异。

根据以上参考文献内容，分析出本文研究重点的振动信号主要是由11个频率点组成的信号。由这11个频率点及其幅值范围来组成振动仿真信号，如式(3-1)所示：

$$\begin{aligned} y(t) = & a_0 + a_1 \sin(2\pi * 100t) + a_2 \sin(2\pi * 2 * 100t) + a_3 \sin(2\pi * 3 * 100t) \\ & + a_4 \sin(2\pi * 4 * 100t) + a_5 \sin(2\pi * 5 * 100t) + a_6 \sin(2\pi * 6 * 100t) \\ & + a_7 \sin(2\pi * 7 * 100t) + a_8 \sin(2\pi * 8 * 100t) + a_9 \sin(2\pi * 9 * 100t) \\ & + a_{10} \sin(2\pi * 10 * 100t) \end{aligned} \quad (3-1)$$

其中， a_0, a_1, \dots, a_{10} 为前文分析出的11个频点的幅值范围，构建模拟振动信号的基频为100Hz。正常振动信号和故障振动信号各频点幅值范围如表3-1所示。

利用上文给出的频率点及每个频率点的幅值范围构建振动仿真信号，设置采样率为125kHz，振动信号周期为0.01秒，即该仿真信号一个周期共有1250个采样点。

表 3-1 振动仿真信号幅值范围表

频率 状态	0	100	200	300	400	500	600	700	800	900	1000
正 常	0.11 至 0.17	1	0.54 至 0.79	0.52 至 0.72	0.35 至 0.43	0.31 至 0.47	0.21 至 0.33	0.14 至 0.20	0.11 至 0.14	0.04 至 0.11	0.06 至 0.10
故 障	0.10 以下	1	0.12 以下	0.15 以下	0.16 以下	0.15 以下	0.09 以下	0.09 以下	0.05 以下	0.04 以下	0.04 以下

3.2 DCGAN 模型基本原理

3.2.1 DCGAN 训练不稳定性分析

DCGAN (Deep Convolution GAN) 网络是将深度卷积网络引入到对抗生成网络中的一个重大尝试, 以卷积层来提取训练样本中的复杂特征。原始的GAN模型并没有规定用以生成的数据的应该以什么格式输入到网络中, 但是深度卷积神经网络多用于解决图像相关问题, 因此DCGAN多被应用于图像方面的生成问题。本文中研究对象为电抗器外壳的振动信号, 受到图像生成问题的启发, 对DCGAN模型进行修改以适应一维数据的特点, 实现电抗器振动数据的生成。DCGAN沿袭了GAN的基本原理, 并选用Adam优化器对网络参数进行优化^[55]。

式 (2-3) 至式 (2-6) 给出了 GAN 的优化训练过程, 由 2.2.2 节的分析可知, 在理想的训练状态下, 判别网络损失函数 d_loss 和生成网络损失函数 g_loss 都应该呈现一个不断下降的趋势, 最终两个损失值都会趋于平稳。这样也说明在训练过程中, 两个子网络都有进一步优化的空间, 其参数找到了一条正确的路径来对自身进行优化, 生成数据的质量也会不断地提升和改善。但如果 d_loss 下降得过快, 迅速变为 0, 说明判别网络已经训练得非常好, 能够轻松地地区分真实数据和来自生成网络生成的

数据。此时,生成网络无法进一步优化自己,生成数据的质量不高,出现过拟合现象。如果 d_loss 和 g_loss 一直处于激烈震荡的状态或者很长的一段时间内都无法收敛,则说明判别网络和生成网络在本次的训练过程中都没有找到一条正确的路径来更新自身的参数,生成数据的质量也就无法得到保障,会生成一系列无规律的条纹,甚至是噪声。

若想要探究清楚 GAN 在训练过程中可能出现不稳定现象的原因,还需要对其损失函数做进一步的研究。

1948 年香农提出信息量的概念,用以描述为消除随机变量 X 在 x 处的不确定性所需要的信息量大小^[56]。可以用式 (3-2) 表示:

$$I = \log(-p(x)) = \log \frac{1}{p(x)} \quad (3-2)$$

式中, I 表示信息量的大小, P 为随机变量 X 的概率分布, $p(x)$ 为随机变量 X 在 $X = x$ 处的概率。由公式可知,若 $p(x)$ 的值越大,信息量 I 的值越小。因为事件发生的概率越大,此处的不确定性就越小,所需消除不确定性的信息量也就越小。反之,若概率 $p(x)$ 越小,不确定性越大,所需的信息量也就越大。

信息量度量的是一个具体事件发生所带来的信息,信息熵则是在结果产生前对可能产生信息量的数学期望。考虑该随机变量的所有可能取值,即所有可能发生事件所带来的信息量期望。对某一事件 X 的信息熵可以用式 (3-3) 计算。

$$\begin{aligned} H(X) &= E_{x \sim P(x)}[-\log p(x)] = -\int p(x) \log \frac{1}{p(x)} dx \\ &= -\sum_{i=1}^n p(x_i) \log(p(x_i)) \end{aligned} \quad (3-3)$$

式中, X 表示所要观测的事件,总共有 n 种情况可能发生。只需要得知事件每一种情况发生的概率 $p(x_i)$ 即可通过式 (3-3) 计算出该事件的信息熵。

KL 散度,又称信息散度,相对熵。 KL 散度可以用来对两个概率分布 P 和 Q 的差

别进行非对称度量。在经典情况下， P 表示数据的真实分布， Q 表示数据的理论分布，模型分布，或者 P 的拟合分布，能够用公式 (3-4) 计算，其数值越大，表示两个概率分布之间的差异越大，反之，则两分布间差异越小。

$$D_{KL}(P \parallel Q) = \sum_i p(x_i) \log \frac{p(x_i)}{q(x_i)} \quad (3-4)$$

D_{KL} 表示使用概率分布 Q 去拟合分布 P 时产生的信息损耗，且是不满足非对称性和三角不等性的，可用公式 (3-5)、(3-6) 表示：

$$D_{KL}(P \parallel Q) \neq D_{KL}(Q \parallel P) \quad (3-5)$$

$$D_{KL}(P \parallel Q) \leq D_{KL}(P \parallel A) + D_{KL}(A \parallel Q) \quad (3-6)$$

JS 散度也可以被用来衡量两个概率分布之间的相似度，是在 KL 散度基础上得到的一种变体，完美地解决了 KL 散度的非对称性。 JS 散度可以用公式 (3-7) 计算：

$$JS(P \parallel Q) = \frac{1}{2} D_{KL}(p(x_i) \parallel \frac{p(x_i) + q(x_i)}{2}) + \frac{1}{2} D_{KL}(q(x_i) \parallel \frac{p(x_i) + q(x_i)}{2}) \quad (3-7)$$

对公式 (3-7) 变形可得到：

$$\begin{aligned} JS(P \parallel Q) &= \sum_{i=1}^n p(x_i) \log(p(x_i)) - \sum_{i=1}^n p(x_i) \log(q(x_i)) \\ &= -H(p(x)) + [-\sum_{i=1}^n p(x_i) \log(q(x_i))] \end{aligned} \quad (3-8)$$

由观察可知，公式的前半部分正好为概率分布 P 的信息熵，公式的后半部分恰好为交叉熵公式，如式 (3-9) 所示：

$$H(P, Q) = -\sum_{i=1}^n p(x_i) \log(q(x_i)) \quad (3-9)$$

在 GAN 中，使用交叉熵作为损失函数，如公式 (3-10)：

$$V(D, G) = E_{x \sim P_{data}(x)} [\log D(x)] + E_{x \sim P_G(x)} [\log(1 - D(x))] \quad (3-10)$$

在上式中， $P_{data}(x)$ 表示真实数据的分布， $P_G(x)$ 表示该模型生成数据的分布。前文中已经指出，生成对抗网络的实质是一个“二元极小极大问题”，为了得到一个最佳的

生成器，即 $G' = \min_G \max_D V(D, G)$ ，首先需要固定生成网络，优先训练判别网络，这一过程表示为公式（3-11）。

$$\begin{aligned} \max_D V(D, G) &= E_{x \sim P_{data}(x)} [\log D(x)] + E_{x \sim P_G(x)} [\log(1 - D(x))] P_G(x) \\ &= \int p_{data}(x) \log D(x) dx + \int p_G(x) [\log(1 - D(x))] dx \end{aligned} \quad (3-11)$$

对于公式（3-11）所述积分，取其最大值，希望对于给定的 x ，积分里的项是最大的，也就是希望取得一个最大的 D' ，最大化式子 $p_{data}(x) \log D(x) + P_G(x) \log(1 - D(x))$ 。在数据给定， G 给定的情况下， $p_{data}(x)$ 和 $P_G(x)$ 可以看作是常数，用 a 、 b 表示，令判别网络的优化目标 $\max_D V(D, G) = f(D)$ ，式（3-11）即可简化为式（3-12）：

$$f(D) = a \log(D) + b \log(1 - D) \quad (3-12)$$

为求取式（3-12）的极大值点，令 $\frac{df(D)}{dD} = a \times \frac{1}{D} - b \times \frac{1}{1 - D} = 0$ ，即可得极大值点如式（3-13）表示：

$$D' = \frac{p_{data}(x)}{p_{data}(x) + p_G(x)} \quad (3-13)$$

从上式中可以看出， D' 的取值范围在 0 到 1 之间。当生成数据的质量特别好，其数据分布非常接近真实数据分布的时候， D' 的值为 $\frac{1}{2}$ ，即此时判别网络无法区分输入数据到底是真实数据还是生成网络生成的数据。

得到了 $V(D, G)$ 取得最大值时的 D ，此时固定判别网络 D ，将 D' 代回 $V(D, G)$ ，如式（3-14）所示：

$$\begin{aligned}
 \max V(D, G) &= V(D', G) \\
 &= E_{x \sim p_{data}(x)} \left[\log \frac{p_{data}(x)}{p_{data}(x) + p_G(x)} \right] + E_{x \sim p_G(x)} \left[\log \frac{p_G(x)}{p_{data}(x) + p_G(x)} \right] \\
 &= \int p_{data}(x) \log \frac{\frac{1}{2} p_{data}(x)}{\frac{p_{data}(x) + p_G(x)}{2}} dx + \int p_G(x) \log \frac{\frac{1}{2} p_G(x)}{\frac{p_{data}(x) + p_G(x)}{2}} dx \\
 &= -2 \log 2 + D_{KL}(p_{data}(x) \parallel \frac{p_{data}(x) + p_G(x)}{2}) + D_{KL}(p_G(x) \parallel \frac{p_{data}(x) + p_G(x)}{2}) \\
 &= -2 \log 2 + 2JS(p_{data}(x) \parallel p_G(x))
 \end{aligned} \tag{3-14}$$

根据以上代入公式求取结果可知，当且仅当 $p_{data}(x) = p_G(x)$ 时，可以取得全局的最小值 $-2 \log 2$ ，此时即可求得所需的最优生成网络 G' 。而最优生成网络 G' 正是使得 G' 的分布 $p_G(x)$ 等于真实数据分布 $p_{data}(x)$ 。

根据式 (3-14) 给出的最佳生成网络公式，可以分析出生成对抗网络的交叉熵损失函数实际上就是生成数据分布 $p_G(x)$ 和真实数据分布 $p_{data}(x)$ 的 JS 距离。可以通过 JS 距离这个指标来观察指导 GAN 的训练过程，寻找最优生成网络和判别网络的过程实际上也就是求解分布 $p_G(x)$ 和 $p_{data}(x)$ 的 JS 距离最小化的过程。在实际的训练过程中，因为 $p_G(x)$ 和 $p_{data}(x)$ 差异非常大，几乎不可能存在相互重叠的部分，所以在判别网络趋近于最优状态时，生成网络的损失函数值近似为一个常数，最终会导致梯度消失现象出现。

从 GAN 的损失函数进行探究，正是因为上述原因，在实际的训练过程中，可能会出现训练不稳定，loss 函数震荡严重或不收敛，生成数据质量差等问题。

3.2.2 稳定 DCGAN 训练的措施

为了稳定 DCGAN 模型的训练过程，避免 loss 曲线出现严重震荡或不收敛、生成数据杂乱无章的情况，对于网络的结构和某些部分的选取做了一些调整。下面本文就

网络调整和采取措施做具体说明。

(1) 批归一化层

在一个网络的训练过程中，网络参数随着训练过程会不断地更新，除了输入层的数据之外，后面每一层的输入都会因为前面网络参数的变化，其数据分布也会发生改变。因为网络下一层的输入是由上一层的输入数据和上一层的参数计算得来的，而上一层的参数在训练过程中会保持更新，所以必然会引起后面每一层网络的输入发生变化，产生内部协变量偏移(Internal Covariate Shift)。批归一化(Batch Normalization, BN)层的引入，解决了中间层网络数据分布发生变化的问题。

批归一化针对的就是一批数据的归一化操作，BN 中的 Batch 即为一个批次的数据量。当前对于网络的训练多采用批梯度下降法，将数据按一定的批大小分为多组，每次针对一个批的数据进行训练，计算损失值，并更新参数。由于每一批的数据量比总体数据量要小很多，训练总时间也会大大缩短，降低了梯度下降的随机性。可以将网络某一层的某个 Batch 输入数据表示为式(3-15)：

$$X = [x_1, x_2, \dots, x_n] \quad (3-15)$$

式中， x_n 表示该在该批次数据中的任意一个数据， n 表示这个批次的数量。可以使用式(3-16)来计算式(3-15)中元素的平均值：

$$\mu_B = \frac{1}{n} \sum_{i=1}^n x_i \quad (3-16)$$

取得元素均值之后，计算该批次数据的方差，用式(3-17)表示：

$$\sigma_B^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \mu_B)^2 \quad (3-17)$$

接下来利用式(3-18)对该批次中的每个元素做归一化处理，式中 ε 是一个非常小的正数。

$$x'_i = \frac{x_i - \mu_B}{\sqrt{\sigma_B^2 + \varepsilon}} \quad (3-18)$$

最后一步，对每个元素进行尺度变换和偏移，如式(3-19)所示：

$$y_i = \gamma_i x_i' + \beta_i \quad (3-19)$$

由上式可知，若尺度变换因子 γ_i 与方差相等，偏置 β_i 与均值相等，则输出结果 y_i 与输入相等，即为一个恒等变换。对于含有 BN 层的网络， γ_i 与 β_i 成为了当前层的训练参数，而不像不含 BN 层的网络一样，是由网络整体的非线性决定的。使用 BN 层之后，能够允许更大的学习率，缩短训练时间；减小对初始化的依赖；利用优化来改变均值和方差大小，使输出更加接近真实分布，确保了网络的非线性；优化了激活函数，使梯度更加平缓，避免了梯度弥散。因此，在对于电抗器振动数据的生成问题中，DCGAN 的各个卷积层之后均加入了批归一化层。

(2) 激活函数

激活函数在神经网络中具有十分关键的作用。在 2.1.2 节中指出，神经网络某一层的输出实质上就是输入与权重之间的矩阵运算。如果不使用激活函数的话，则这一运算就是一个线性运算。线性模型比较简单，不管网络整体有多少层，如果下一层的输出实际上只是承担了上一层输入的线性变换，则网络最终的输出仍是一个线性的模型。线性的结构不能很好地应用于复杂的应用场景，对解决特征复杂的问题存在着很大的难度。这时，就有必要引入激活函数，给神经元加入非线性因素，使其能够逼近任意的非线性函数，将神经网络变为一种非线性的模型。

在稳定 DCGAN 模型的训练过程中，主要使用了 Sigmoid、LeaklyReLU 和 Tanh 函数，下面分别对这几个激活函数进行说明和分析。

Sigmoid 函数用于判别网络最后输出的那一层，因为在 DCGAN 中判别网络实际上就是一个二分类网络，因此选用 Sigmoid 函数。

Sigmoid 函数的表达式可以定义为式 (3-20)：

$$f(x) = \frac{1}{1 + e^{-x}} \quad (3-20)$$

Sigmoid 函数的导函数计算如下式所示：

$$f'(x) = \left(\frac{1}{1 + e^{-x}} \right)' = \frac{e^{-x}}{(1 + e^{-x})^2} = f(x)(1 - f(x)) \quad (3-21)$$

Sigmoid 函数的图像如图 3.1 所示：




图 3.1 Sigmoid 函数曲线图

由上图可以看出，Sigmoid 函数的值域为 $(0,1)$ ，由式 (3-21) 可知求导公式十分简单，便于反向传播过程时导数的计算。但是在 Sigmoid 函数的输入值非常大或者非常小的时候，其导函数值接近于 0，可能导致网络参数更新时局部梯度也趋近于 0，网络参数几乎不更新。

DCGAN 中生成网络最后一层的激活函数选用 Tanh 函数。Tanh 函数可以定义如下：

$$f(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}} \quad (3-22)$$

Tanh 函数的导函数如下所示：

$$f'(x) = \left(\frac{e^x - e^{-x}}{e^x + e^{-x}} \right)' = \frac{4}{(e^x + e^{-x})^2} = 1 - f^2(x) \quad (3-23)$$

Tanh 函数的图像如图 3.2 所示。由图 3.2 可知，Tanh 函数的值域为 $(-1,1)$ ，在 0 附近的一个小区间内可以近似为一个线性函数，且由式 (3-23) 知其导数的计算过程也很简单。与 Sigmoid 函数相比，Tanh 函数的均值为 0，且收敛速度更快。但 Tanh 函数存在着与 Sigmoid 函数相同的问题，容易出现梯度消失。




图 3.2 Tanh 函数曲线图

生成网络中除开最后一层之外，激活函数均选用 ReLu 函数。而在判别网络中，除最后一层外，其余位置的激活函数均选用 LeakyRelu 函数，而非 ReLu 函数。ReLu 函数的定义如下所示：

$$f(x) = \begin{cases} x, & x \geq 0 \\ 0, & x < 0 \end{cases} \quad (3-24)$$

ReLu 函数的导函数定义为：

$$f'(x) = \begin{cases} 1, & x \geq 0 \\ 0, & x < 0 \end{cases} \quad (3-25)$$

ReLu 函数的函数曲线如下所示：




图 3.3 ReLu 函数曲线图

观察上图可以得知, ReLu 函数在 $x < 0$ 时, 输出值为 0, 在 $x \geq 0$ 时有非零的输出, 这样的特性为神经网络增加了稀疏性, 降低了网络中不同参数之间的依存关系, 在一定程度上缓解了训练过程中网络过拟合的问题。与 Tanh 函数和 Sigmoid 函数相比较, ReLu 函数能够大大地加快随机梯度下降算法的收敛过程, 由于其分段输出的特性, 避免了类似于前两种函数中复杂的指数运算, 节省了计算机运算量, 缩短了训练总时间。同样地, ReLu 函数作为激活函数使用时也存在着一定的缺陷。由于 ReLu 函数的分段输出特性, 一个非常大的梯度经过其激活并更新参数之后, 这个神经元不会再次被激活, 之后任何流经该神经元的梯度输出均为 0, 极大地损害了数据的多样性。在实际训练中, 往往由于学习率设置过大, ReLu 单元出现不可逆转的死亡, 参数无法继续更新。为了克服上述神经元可能无法被激活的缺点, ReLu 函数出现了非常多的改进版本, 例如 LeakyReLu。LeakyReLu 函数可表示为:

$$f(x) = \begin{cases} x, & x \geq 0 \\ ax, & x < 0 \end{cases} \quad (3-26)$$

其中 a 是一个较小的正数, 通常被设置 0.01。与 ReLu 函数不同的是, 在 $x < 0$ 时输出不为 0, 而是输出一个斜率较小的线性函数。

3.3 电抗器仿真振动信号的生成

为了避免传统基于物理特性建模方法存在的物理特征难以提取以及方法应用场景局限性大, 无法推广到其他应用场景的缺陷, 本文采用深度学习技术, 以数据为驱动, 从大量数据中训练学习到规律, 提取到数据特征。但是电网数据的一个明显特点是数据价值密度很低, 即电网设备多处于正常运作状态, 采集到的处于异常工作状态下的数据非常少。因此, 对于扩充异常样本数据的研究也就成为一个十分重要的课题。

本节采用 DCGAN 进行振动信号的生成, 将卷积神经网络与对抗生成网络相结合, 利用卷积神经网络出色的提取数据特征的性质, 对整个组合网络进行无监督的训练。这种网络结构能更好地学习到振动数据背后蕴含的规律, 在训练过程中更加稳定、更易收敛, 并生成质量更高的数据。整个生成对抗网络的结构示意图如图 3.4 所示。

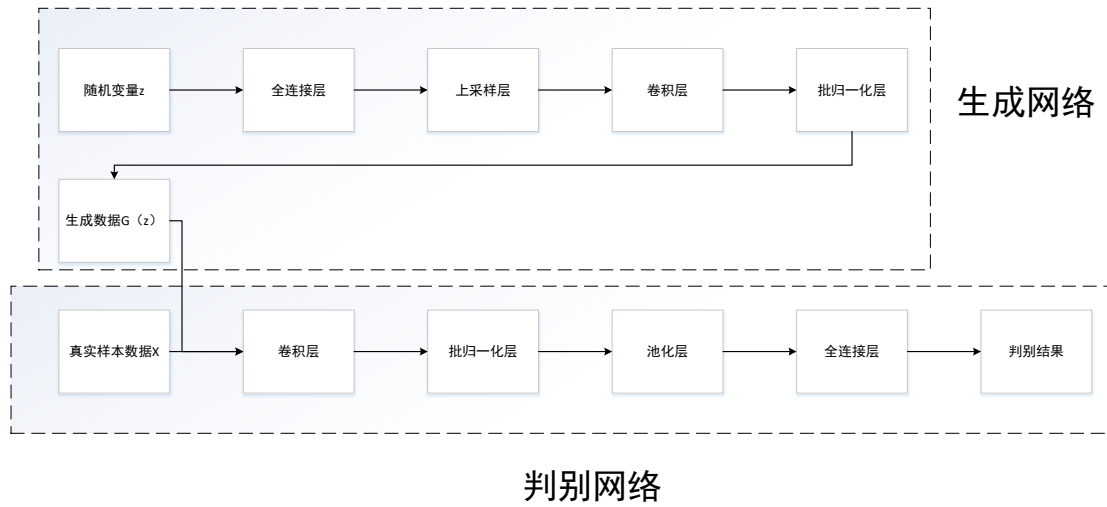


图3.4 DCGAN网络结构示意图

在卷积网络中，一般采用二维卷积核，且多用于图像的处理。但经实验验证，将电抗器振动仿真信号转为矩阵格式输入到含有二维卷积层的DCGAN中进行训练，loss曲线不收敛且生成信号质量不高，甚至生成噪声。这是因为振动信号是一维数据格式，具有很强的时间相关性，但转化成二维格式后并不具备图片上下左右相邻像素点之间的关联，无法将一维时间序列的信号按照二维图片的格式进行训练。因此，将该DCGAN中的二维卷积核全部替换为一维卷积核，直接使用原振动信号格式进行训练。

由于DCGAN网络结构比较复杂，层数较多，下面将判别网络和生成网络的网络参数分别用一个表格来记录。生成网络的每层参数如表3-2所示。其中，填充方式指的是网络的padding参数，即数据周围一圈填充的元素个数，步长指的是卷积核每次移动的距离。如对于第二层，是卷积层加批归一化层的组合，激活函数为ReLU，卷积核大小为3，卷积核个数为128，步长为1，参与该层运算之后输出的数据大小为128*39。

在生成网络中输入一个长度为250维的高斯随机噪声向量，经过一个全连接层扩充后调整数据格式变为一个256通道的数据。每个一维卷积层后添加一个批归一化层，来增加网络的稳定性，并加入一个上采样层，维持数据规模。除输出层采用Tanh激活函数外，其余各卷积层均使用ReLU激活函数。各层参数经过调整和设计之后，保证

华中科技大学硕士学位论文

网络最终输出维度与算例中输出数据维度一致，输出一个长度为1250维的向量。

表3-2 生成网络各层参数表

层数	名称	卷积核大小	卷积核个数	步长	填充方式	上采样因子	动态均值动量	输出
输入层	Input 1*250							
1	FC+ReLU							256*39
2	Conv1+BN	3	128	1	1		0.8	128*39
	ReLU							
3	UpSample1					2		128*78
4	Conv2+BN	3	64	1	1		0.8	64*78
	ReLU							
5	UpSample2					2		64*156
6	Conv3+BN	3	32	1	1		0.8	32*156
	ReLU							
7	UpSample3					2		32*312
8	Conv4+BN	3	16	1	1		0.8	16*312
	ReLU							
9	UpSample4					2		16*624
10	Conv5+BN	2	8	1	1		0.8	8*625
	ReLU							
11	UpSample5					2		8*1250
12	Conv6+Tanh	3	1	1	1			1*1250

判别网络结构和生成网络结构基本相似，两者呈对称分布。但是与生成网络不同的点在于，将每一卷积层的激活函数由ReLU函数替换为LeaklyReLU函数，卷积层之间加入了池化层以减小数据规模，最终网络输出部分的激活函数设置为Sigmoid函数。判别网络每层的具体参数见表3-3所示。

表3-3 判别网络各层参数表

层数	名称	卷积核大小	卷积核个数	步长	填充方式	动态均值动量	输出
输入层	Input 1*1250						
1	Conv1+BN	3	8	1	1	0.8	8*1250
	LeaklyReLU						
2	MaxPool1	3		2	0		8*624
3	Conv2+BN	3	16	1	1	0.8	16*624
	LeaklyReLU						
4	MaxPool2	3		2	1		16*312
5	Conv3+BN	3	32	1	1	0.8	32*312
	LeaklyReLU						
6	MaxPool3	3		2	1		32*156
7	Conv4+BN	3	64	1	1	0.8	64*156
	LeaklyReLU						
8	MaxPool4	3		2	1		64*78
9	Conv5+BN	3	128	1	1	0.8	128*78
	LeaklyReLU						
10	MaxPool5	3		2	1		128*39
11	Conv6+BN	3	256	1	1		256*39
	LeaklyReLU						
12	Fc						800
13	Fc						1

此处，DCGAN模型选用交叉熵作为训练的损失函数。由前文论述可知，该模型具有两个损失：判别网络损失 d_loss 和生成网络损失函数 g_loss 。其中， d_loss 可以用式 (3-27) 计算。 d_loss 也是由两个loss值的和取平均得到，其中 $d_{realloss}$ 指的是判别网络对真实样本输出的判别结果与预期结果1之间的交叉熵， $d_{fakeloss}$ 表示生成样本输入判别器后的判别结果与预期结果0之间的交叉熵。 g_loss 是由生成样本与真实样本之间的交叉熵计算得到。

$$d_loss = \frac{1}{2}(d_{realloss} + d_{fakeloss}) \quad (3-27)$$

可以使用该 DCGAN 模型分别生成正常振动信号和故障振动信号，下面以故障振

动信号为例，来说明整个网络的训练过程，并展示最终的信号生成效果。首先使用式（3-1）作为振动信号的仿真模型，同时以表 3-2 中给出的振幅范围表为参数来构建故障振动仿真信号。从该仿真模型中共采集 1000 个信号作为本次训练所使用的训练集，训练集中的每个数据均是一个由 1250 个采样点组成的一个完整周期的信号。DCGAN 属于无监督学习的范畴，所以无需给数据集中的数据加上标签，且训练 DCGAN 不用划分测试集。

在本次训练过程中，为保证 loss 曲线收敛和生成信号的稳定，设置生成网络训练次数与判别网络训练次数为 2:1，生成网络学习率为 0.001，判别网络学习率为 0.00002，网络参数更新使用 Adam 优化器，批大小设置为 64，总共训练 200 轮（epoch）。另外，可以将不同训练轮次下的模型参数保存下来，分别生成在该模型参数下的信号，以故障仿真振动信号为例，可视化如图 3.5 所示。

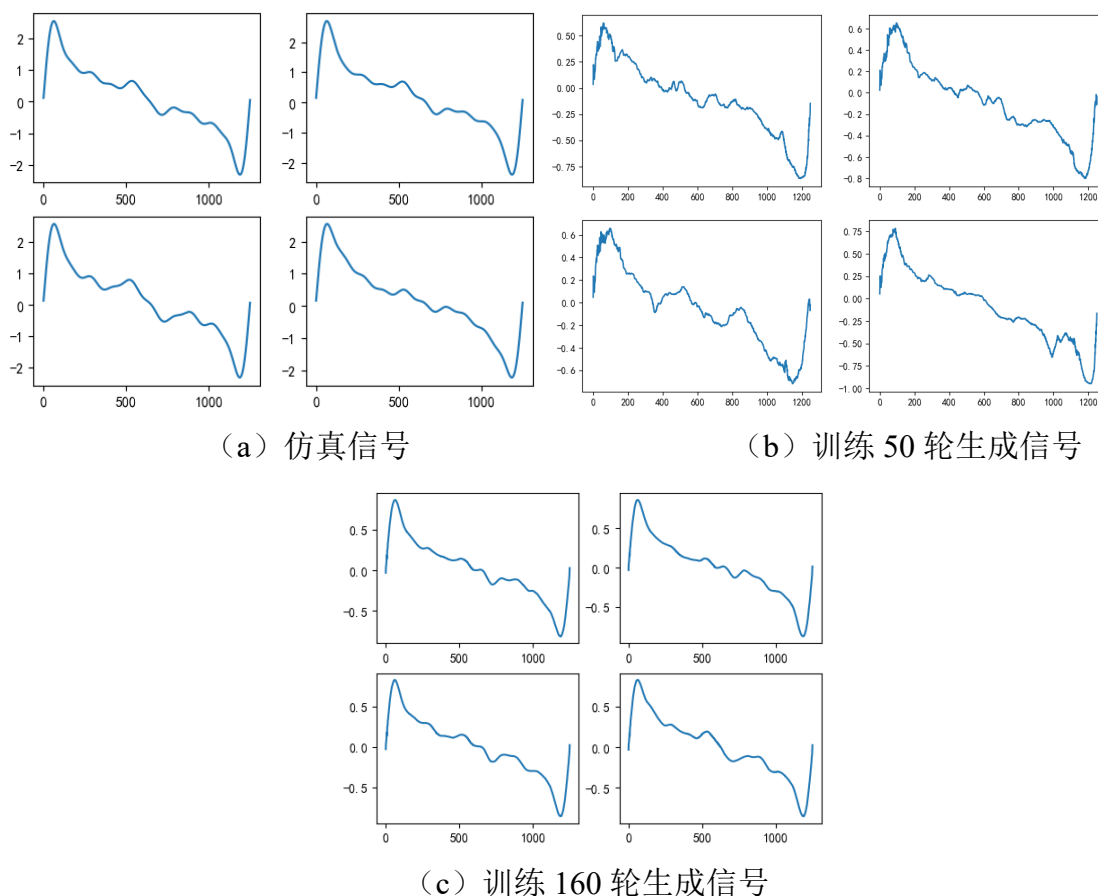


图 3.5 仿真信号与各轮次生成信号对比

上图展示了用以训练的数据样本和使用DCGAN在不同训练轮次下生成信号的图像，图(a)为用于训练的仿真振动信号可视化结果，图(b)为训练50轮后生成信号可视化结果，图(c)为经过160轮训练之后的可视化结果。观察三组图可以发现，经过50轮训练后，生成信号已初具仿真振动信号的形状，但是生成的信号曲线不平滑，带有许多毛刺，说明该模型已大致学习到训练集的数据分布，但离训练集真实分布仍有一定差距。经过160轮训练之后，生成信号已经相当接近仿真振动信号。

余弦相似度作为衡量两个向量之间的差异大小的一项指标，可以用来评判生成信号与用以训练的仿真信号之间的相似度。余弦相似度即向量空间中两个向量之间夹角的余弦，其值越接近于1，则两向量间夹角越趋近于0度，两个向量的相似度也就越高。余弦相似度可以用式（3-28）来计算：

$$\cos(\theta) = \frac{\sum_{i=1}^n (x_i \times y_i)}{\sqrt{\sum_{i=1}^n x_i^2} \times \sqrt{\sum_{i=1}^n y_i^2}} \quad (3-28)$$

其中一个向量为 $\mathbf{a} = (x_1, x_2, \dots, x_n)$ ，另一个向量为 $\mathbf{b} = (y_1, y_2, \dots, y_n)$ 。

为了能够定量地评估 DCGAN 生成信号的效果，从仿真振动信号、训练 50 轮生成信号和训练 160 轮生成信号中各随机抽取 100 个信号，分别计算仿真信号与训练 50 轮生成信号、仿真信号与训练 160 轮生成信号之间的余弦相似度，取平均值，结果如表 3-4 所示。

表 3-4 训练 50 轮、160 轮生成信号余弦相似度对比

比较信号	训练 50 轮生成信号	训练 160 轮生成信号
余弦相似度	0.778	0.991

由上表可发现，经过 160 轮训练后生成信号与仿真信号的相似度要高于经过 50 轮训练生成信号，与人眼的主观观察结果相吻合。

图3.6展示了训练次网络时其loss曲线的变化。图中，generator loss表示生成网络的loss值，discriminator loss表示判别网络的loss值。观察该曲线图，发现DCGAN在训练初期500次迭代以内loss曲线震荡非常激烈，此时判别网络和生成网络正在相互对

抗。但随着训练轮次的增多，两个网络的loss曲线逐渐收敛，当经过3000次迭代之后，最终达到了“纳什均衡”。




图3.6 DCGAN训练loss曲线图

为了验证批归一化层对DCGAN训练稳定性的影响，保持训练参数不变，将上述DCGAN模型中的各归一化层全部去掉，训练200轮，其loss曲线如图3.7所示。由图可知，在3000次迭代以内，两网络的loss曲线均无法收敛，验证了批归一化层对稳定DCGAN训练的有效性。

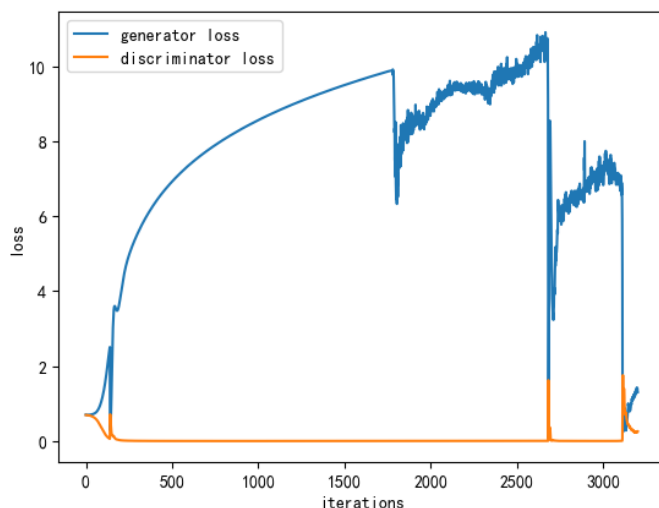


图3.7 不含批归一化层DCGAN训练loss曲线图

3.4 基于 CNN 的仿真故障振动信号识别

为有效识别出电抗器的故障振动信号，采用CNN来建立故障振动信号识别模型。针对振动信号的一维时序特点，提出一维CNN模型，并介绍了其网络结构及网络每一层的具体参数。以3.1节中介绍的电抗器振动信号模型来产生仿真数据，作为搭建的一维CNN故障振动信号识别模型的数据集，训练和测试该网络，并分析实验结果。

3.4.1 一维 CNN 的网络结构及参数

在卷积网络中，一般的卷积核多为二维结构，且多用于图像的处理。但经实验验证，将电抗器振动信号转为矩阵格式进行训练，loss曲线不收敛且生成数据质量不高，甚至生成的是噪声。这是因为振动信号是一维数据格式，具有很强的时间相关性，但转化成二维格式后并不具备图片上下左右相邻像素点之间的关联，无法将一维时间序列的信号按照二维图片的格式进行训练。所以，在网络设计时，将二维卷积核替换为一维卷积核，直接把一维的振动信号作为数据集输入到CNN中进行训练。

在本节的电抗器故障振动信号识别问题中，训练集数据由第三章中介绍的经过振动信号仿真模型产生的数据（包含正常信号与故障信号）组成，数据格式为含有1250个采样点的一维数据。针对该问题设计的一维CNN结构如图3.8所示。从图中可以得知，该网络模型共有11层，其中包含5个卷积层，5个池化层和1个全连接层。但是每一层更为详细的参数设置没有在图中表现出来，例如卷积核的大小和设置的步长，卷积层或者池化层的填充方式，即padding值的设置，激活函数ReLU的斜率，卷积层是否加入偏置等。

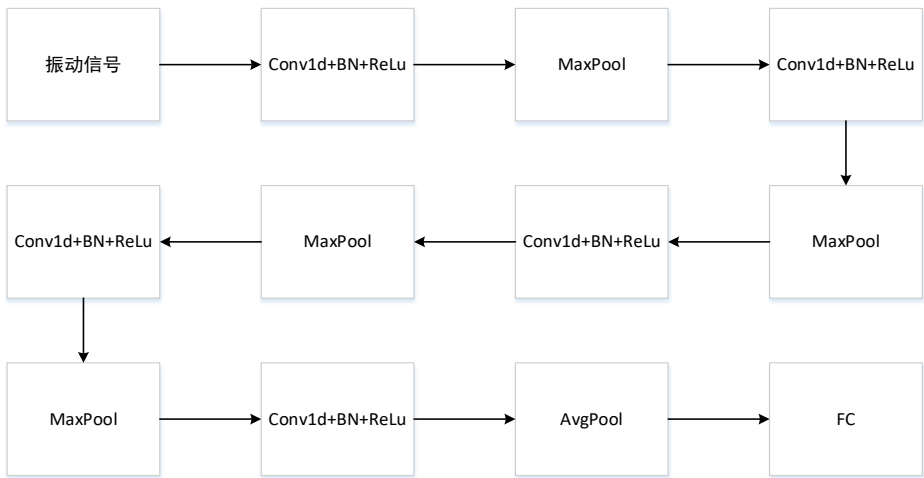


图3.8 一维CNN网络结构

接下来，可以使用一个表格来记录网络各层的具体参数，如表3-5所示。

表3-5 一维CNN网络参数表

层数	名称	卷积核大小	卷积核个数	步长	填充方式	动态均值动量	输出
输入层	Input 1*1250						
1	Conv1+ BN	3	8	1	1	0.8	8*1250
	ReLU						
2	MaxPool1	2		2	0		8*625
3	Conv2+BN	3	16	1	1	0.8	16*625
	ReLU						
4	MaxPool2	3		5	1		16*125
5	Conv3+BN	3	32	1	1	0.8	32*125
	ReLU						
6	MaxPool3	3		5	1		32*25
7	Conv4+BN	3	64	1	1	0.8	64*25
	ReLU						
8	MaxPool4	3		5	1		64*5
9	Conv5+BN	3	128	1	1	0.8	128*5
	ReLU						
10	AvgPool	3		5	1		128*1
11	Fc						1

3.4.2 CNN 识别结果与分析

在训练该基于CNN的故障振动信号识别模型时，以3.1节中阐明的电抗器振动信号仿真模型产生数据来构建数据集，产生等量的故障振动信号和正常振动信号，共1000个，并且给数据集中的数据打上标签，故障振动信号标记为“1”，正常振动信号标记为“0”。按照8:2的比例从数据集中随机抽取数据，将其划分为训练集和测试集。

对于训练过程中的一些超参数的设置，作如下说明：

(1) 训练此一维CNN时，每个训练样本为一个含有1250个采样点的振动信号，每个批次选取64个样本进行训练，总共训练20轮。

(2) 舍弃固定学习率的方案，采用退化学习率的方式来代替，使得网络训练时能在训练速度和稳定性之间达到一个平衡。设置初始学习率为0.001，每10个轮次学习率衰减为原有学习率的十分之一。

(3) 选用Adam优化器更新网络参数，并使用softmax交叉熵作为损失函数。

接下来就可以按照上文给出的网络结构和参数来训练和测试该一维CNN。使用该CNN在未加入生成信号的训练集和加入生成信号的训练集上进行训练，未加入生成数据的训练集和测试集的数量比为800:200。在原有训练集的基础上还加入了等量的使用DCGAN生成的振动信号，并且生成信号中故障振动信号数量与正常振动信号数量比为1:1，即加入生成信号后的训练集和测试集的数量比为1600:200。同时，每次缩小原有训练集中的数据量，重复进行如上实验，分别统计加入DCGAN生成数据前后CNN的识别准确率以及加入线性插值方法SMOTE算法生成数据后CNN的识别准确率，实验结果如表3-6所示。折线图3.9更为直观地展示了不同方法间识别率的差异。

由表3-6可以得出本文设计的一维CNN对于识别电抗器故障振动信号具有良好的效果，在原始数据集上可达到100%的识别率。另外，在数据集数据量小于800的情况下，可以使用DCGAN对数据集进行扩充，提升识别率，且DCGAN对识别率的提升效果要优于SMOTE算法。

表3-6 原始数据集和扩充数据集识别准确率

训练集大小	是否扩充	扩充后训练集大小	数据扩充算法	识别准确率 (%)
200	否	200		50
200	是	400	SMOTE	62
200	是	400	DCGAN	66.5
300	否	300		60.5
300	是	600	SMOTE	76
300	是	600	DCGAN	79.5
400	否	400		72
400	是	800	SMOTE	94.5
400	是	800	DCGAN	96.5
600	否	600		86
600	是	1200	SMOTE	100
600	是	1200	DCGAN	100
800	否	800		100
800	是	1600	SMOTE	100
800	是	1600	DCGAN	100




图3.9 原始数据集和扩充数据集识别准确率

为了比较样本数对于CNN识别率的影响，在网络各参数不变的情况下，分别统计

华中科技大学硕士学位论文

利用DCGAN、SMOTE算法生成信号扩充训练集和只含有仿真振动信号数据的数据集下的识别率。使用400个仿真振动信号加上400个由DCGAN或SMOTE算法生成信号的训练集进行实验，并与含有800个仿真振动信号的训练集进行比较。测试集含有200个仿真振动信号并保持不变。在改变只含有仿真数据的训练集和加入生成信号训练集的数据量的情况下，进行多次实验。实验结果如下图表所示。

表3-8 仿真振动信号数据集与生成扩充数据集比较

实验数	训练集大小	识别准确率 (%)
实验 1	100 (仿真) + 100 (SMOTE 生成)	45
实验 2	100 (仿真) + 100 (DCGAN 生成)	47.5
实验 3	200 (仿真)	50
实验 4	200 (仿真) + 200 (SMOTE 生成)	62
实验 5	200 (仿真) + 200 (DCGAN 生成)	66.5
实验 6	400 (仿真)	72
实验 7	300 (仿真) + 300 (SMOTE 生成)	76
实验 8	300 (仿真) + 300 (DCGAN 生成)	79.5
实验 9	600 (仿真)	86
实验 10	400 (仿真) + 400 (SMOTE 生成)	94.5
实验 11	400 (仿真) + 400 (DCGAN 生成)	96.5
实验 12	800 (仿真)	100




图3.10 采集扩充数据集与生成扩充数据集比较

从表3-8中可以明显看出，DCGAN扩充训练集的方法和SMOTE算法扩充训练集的方法对识别率的改善能力要低于直接使用原始振动仿真信号数据扩充训练集的方法，但是DCGAN扩充训练集的识别率稍高于SMOTE算法扩充训练集。而且采用这三种方法后的识别率非常接近，说明DCGAN生成数据虽然无法完全等同于真实采集的数据，但是两者之间的差异比较小，在原始数据难以采集的情况下，可以作为代替，完成对原数据集的扩充，提高识别准确率。

3.5 本章小结

本章主要针对电抗器振动数据的生成和识别进行研究。首先，本章根据实采的电抗器振动数据的频谱分析，建立了振动信号仿真模型。然后，从损失函数的角度出发，分析了DCGAN在实际训练时存在不稳定现象的原因，并随后给出了一些稳定其训练的解决措施。另外，还设计了用以生成振动信号的DCGAN，并用振动仿真信号来测试设计的DCGAN的数据生成效果，采用余弦相似度对生成信号进行度量，与真实信号非常接近，符合肉眼主观评价，具有良好的生成效果。为了解决高压电抗器故障振动信号识别的问题，设计了针对一维振动数据的CNN分类网络，以3.1节中介绍的电抗器振动仿真模型采样得到的数据和DCGAN和SMOTE算法生成的样本作为数据集，仿真实验结果证明了CNN分类方法的有效性，在训练集数据量达到800时，识别率可达到100%，并且加入生成信号的训练集其识别率要低于与其等量的全部由仿真信号

构成的训练集。

4 BKD2-140000/800-110 型高压电抗器故障振动信号生成与识别

在本章中，以BKD2-140000/800-110型高压电抗器上加装的振动传感器采集到的振动信号作为数据集，选用Pytorch框架作为整个实验的平台，详细介绍了实验中用到的神经网络的结构设计和具体的参数设置，使用一维DCGAN完成高压电抗器实采振动信号的生成，并使用一维CNN完成对该型号电抗器故障振动信号的识别。

4.1 实验平台及数据集

近年来，深度学习概念逐渐被人熟知，其相关研究和应用大量涌现。为了满足学术和工业界的研究需求，降低开发门槛，各种开源深度学习框架应运而生，比较常见的如Google的Tensorflow，Facebook的Pytorch，百度的Paddle Paddle，Caffe，MXNet，Keras，Theano等。本章选用Pytorch框架进行模型的搭建和训练。

Pytorch是Facebook于2017年公布的开源深度学习框架，为torch的Python版本。Pytorch与Tensorflow的不同之处在于两者具有不同的计算图实现形式，前者是基于动态图机制运算的，而后者采用静态图机制。Pytorch的设计十分简洁，避免更多的封装，总体遵循着张量（tensor）、变量（自动求导）和神经网络（模块/层）的三层次结构设计，也就是说网络各结构均有独立的子模块，可以同时进行操作和修改。而且，其灵活性并不以牺牲运行速度为代价，在很多测试中，其运行速度还要高于Tensorflow和Keras等框架。Pytorch框架基于张量展开计算，可以动态地构建网络，有众多的支持库（NumPy、SciPy等），设计更为简洁、易用。因此在本章实验中选择其作为实验环境。

本文实验环境为 Intel(R) Core(TM) i7-8700 CPU @3.20GHz 处理器，16GB 内存，NVIDIA GeForce GTX 1060 6GB GPU，Anaconda 3.5.1。在 PyTorch 框架下实现所有实验分析。

本章中实验所需的实验数据均来自于BKD2-140000/800-110型高压电抗器油箱表

面振动传感器采集的数据。振动传感器对A、B、C每一相单独采集其振动信号，电抗器油箱外表的前后左右四面均安装有振动传感器，每一个面上安装有9个传感器。振动传感器采集到的A相信号数量如表4-1所示。B、C两相传感器分布和采集信号数量与A相相同。

表4-1 A相传感器采集振动信号数量

采集面数	每面传感器数	每传感器采集信号数
4	9	125000

电抗器传感器在某一面上的安装位置如图4.1所示所示。




图4.1 油箱某一面振动传感器安装位置示意图

在A、B、C三相采集数据中，正常工作状态下电抗器振动数据与故障状态下电抗器振动数据各采集了15000组，共30000组数据构成整个本次实验所需的数据集。电抗器振动传感器的采样率为1.25MHz，采样间隔为 8×10^{-7} 秒，振动信号周期为0.01秒，即一个振动周期采样了12500个点。由于实采数据一个周期的数据量过大，会对后续DCGAN模型生成信号和CNN模型对故障振动信号进行识别造成实际操作上的困难，影响信号生成效果和分类识别的准确率，所以对实采数据进行降采样，设置采样率为125kHz，即一个周期采样了1250个点。

某一传感实际采集的A相振动信号如图4.2所示。该信号是一个长度为10个周期的振动信号。




图4.2 某A相振动传感器实际采集信号

4.2 一维 DCGAN 和一维 CNN 网络设计

在生成振动信号时首先考虑将第3章中设计的针对振动仿真信号的DCGAN直接迁移到BKD2-140000/800-110型电抗器振动信号的生成问题中。但是，经过实际操作发现该模型在此数据背景下loss曲线无法收敛，所以考虑对该网络模型进行修改。用以生成振动信号的DCGAN中生成网络的设计与第3章中用以生成振动仿真数据的网络中的生成网络完全相同，而判别网络根据数据的变化，其网络结构和参数的设置也做了相应调整。与第3章中判别网络不同的是，池化层MaxPool的步长增大为5，卷积层的数量也由6层减少至5层，最终网络经过一个AvgPool后输出。调整后的判别网络结构如图4.3所示。

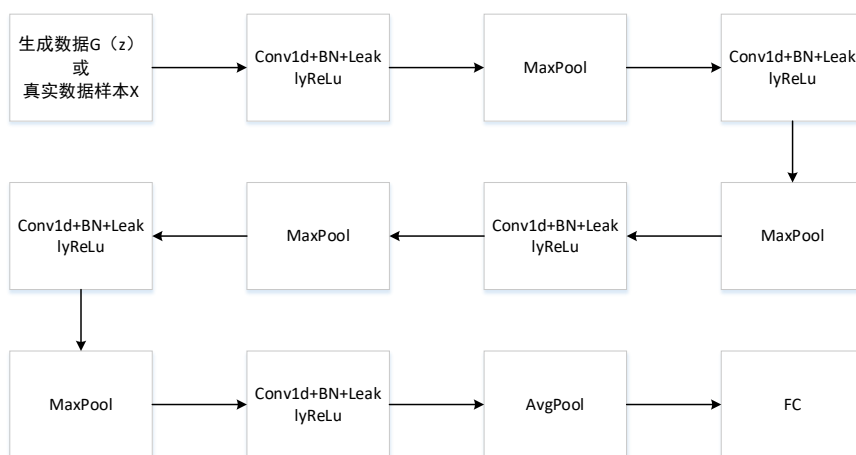


图4.3 判别网络结构示意图

可以用一个表来详细地记录判别网络的各层参数，如表4-2所示。

表4-2 判别网络各层参数

层数	名称	卷积核大小	卷积核个数	步长	填充方式	动态均值动量	输出
输入层	Input 1*1250						
1	Conv1+BN	3	8	1	1	0.8	8*1250
	LeaklyReLU						
2	MaxPool1	2		2	0		8*625
3	Conv2+BN	3	16	1	1	0.8	16*625
	LeaklyReLU						
4	MaxPool2	3		5	1		16*125
5	Conv3+BN	3	32	1	1	0.8	32*125
	LeaklyReLU						
6	MaxPool3	3		5	1		32*25
7	Conv4+BN	3	64	1	1	0.8	64*25
	LeaklyReLU						
8	MaxPool4	3		5	1		64*5
9	Conv5+BN	3	128	1	1	0.8	128*5
	LeaklyReLU						
10	AvgPool	3		5	1		128*1
11	Fc						1

本章中的电抗器故障识别模型的结构设计与第3章中卷积神经网络的结构设计一致，参数不变。整个网络结构包含有5个卷积层，5个池化层和1个全连接层。将实际采集的电抗器振动信号与DCGAN生成的信号一起送入到该网络中，统计识别的准确

率。

4.3 实验结果与分析

将 4.1 节中介绍的由采集的振动信号构建的数据集按照 7:3 的比例从样本数据中随机抽取作为训练集和测试集。

实验过程中为了保证训练模型稳定、收敛且判别网络损失值过小变为 0，设置生成网络训练次数与判别网络训练次数为 2:1，生成网络学习率为 0.001，判别网络学习率为 0.00002。使用 Adam 优化器对网络参数进行迭代更新，并设置批大小为 256，训练生成网络模型。

以故障状态下电抗器振动数据样本为例，图 4.4 分别显示训练集中实际采集的故障振动信号和利用 DCGAN 经过 200 轮训练后生成的故障振动信号。可以观察到生成样本与训练样本比较接近。




图4.4 训练集信号和生成信号图像

上文构建数据集经过200轮训练后，其loss曲线如图4.5所示。其中，generator loss表示生成网络的损失值，discriminator loss表示判别网络的损失值。从图中可以观察到，在5000次迭代以内，判别网络与生成网络相互博弈，对抗训练，loss曲线波动很大。但在训练超过10000次迭代之后，判别网络和生成网络的loss曲线趋于平稳并收敛。总体上来说，判别网络的loss曲线呈现下降趋势，而生成网络的loss曲线呈现上升

趋势，在本算例的训练过程中，判别网络的训练效果要优于生成网络。




图4.5 DCGAN模型训练loss曲线图

为了验证生成的振动信号的有效性，采用第四章介绍的一维 CNN 来测试生成信号的分类准确率，网络结构和训练参数均保持不变。在训练集的基础上，生成等量的正常振动信号和故障振动信号，并加入到原始训练集中，保证扩充后的训练集是原始训练集的 2 倍，比较原始数据集和扩充数据集在 CNN 分类网络下的分类准确率。扩充前原始数据集训练集和测试集数量比为 21000:9000，加入生成信号后的数据集中训练集和测试集数量比为 42000:9000。

由于 CNN 的分类准确率受到数据量大小的影响，本文还探究了 DCGAN 生成信号提升分类准确率的有效数据范围。每次将训练集的数据量缩减一半，然后用分类网络对缩减后的训练集和用 DCGAN 扩充后的训练集进行分类，统计其分类准确率。扩充后训练集的数据量为扩充前的两倍。不同数据规模的训练集和其扩充数据集在 CNN 中的分类准确率如表 4-3 所示。各分类准确率可以用折线图 4.6 更为直观地表示。

华中科技大学硕士学位论文

表4-3 原始数据集和扩充数据集识别准确率

训练集大小	是否扩充	扩充后训练集大小	数据扩充算法	识别准确率 (%)
1312	否	1312		83.38
1312	是	2624	SMOTE	84.62
1312	是	2624	DCGAN	85.77
2624	否	2624		87.58
2624	是	5248	SMOTE	89.21
2624	是	5248	DCGAN	91.04
5250	否	5250		93.63
5250	是	10500	SMOTE	95.73
5250	是	10500	DCGAN	96.09
10500	否	10500		98.52
10500	是	21000	SMOTE	98.76
10500	是	21000	DCGAN	99.18
21000	否	21000		99.81
21000	是	42000	SMOTE	99.91
21000	是	42000	DCGAN	99.97




图4.6 原始数据集和扩充数据集识别准确率

华中科技大学硕士学位论文

从表中可知, 利用 DCGAN 生成数据扩充后的训练集比原有训练集的认识率更高。同时, 在数据集的数据量达到 21000 后, DCGAN 扩充数据集对识别准确率的提升很微小, 且需加入较大量的数据, 数据利用效率很低。因此, 在本算例中, 训练集数据规模在 21000 以下时, 使用 DCGAN 扩充数据对于提升原有训练集的分类准确率是有效的。而且在训练集大小为 1312 至 21000 的范围内, 使用 DCGAN 扩充训练集方法对识别率的提升效果要优于使用 SMOTE 算法进行训练集扩充的方法, 可以提高原有训练集识别率 3%左右。

为了比较生成振动信号与传感器采集振动信号之间的差异, 本文还设计了如下实验进行说明。如表 5-4 所示, 实验 2、实验 5、实验 8、实验 11 中使用的训练集是由等量的电抗器振动传感器采集的信号和使用 DCGAN 生成的信号构成的, 而实验 1、实验 4、实验 7、实验 10 中使用的训练集是由等量的传感器采集的信号和使用 SMOTE 算法生成的信号构成。实验 3、实验 6、实验 9、实验 12 中使用的训练集全部为传感器采集信号, 且分别与实验 1 和实验 2、实验 4 和实验 5、实验 7 和实验 8、实验 10 和实验 11 中使用的训练集数据量相等。表中内容可以用折线图 4.7 直观比较。

表 4-4 传感器采集信号与混合生成信号的比较

实验	训练集大小	识别准确率 (%)
实验 1	1312 (采集) +1312 (SMOTE 生成)	84.62
实验 2	1312 (采集) +1312 (DCGAN 生成)	85.77
实验 3	2624 (采集)	87.58
实验 4	2624 (采集) +2624 (SMOTE 生成)	89.21
实验 5	2624 (采集) +2624 (DCGAN 生成)	91.04
实验 6	5248 (采集)	93.63
实验 7	5250 (采集) +5250 (SMOTE 生成)	95.73
实验 8	5250 (采集) +5250 (DCGAN 生成)	96.09
实验 9	10500 (采集)	98.52

实验 10	10500（采集）+10500（SMOTE 生成）	98.76
实验 11	10500（采集）+10500（DCGAN 生成）	99.18
实验 12	21000（采集）	99.81

从表 4-4 中可以观察到，一半传感器采集信号和一半 DCGAN 生成信号组成的训练集和一半传感器采集信号和一半 SMOTE 算法生成信号组成的训练集的认识率均要低于与其等量的完全由传感器采集数据构成的训练集的认识率，但是三者的认识准确率十分接近，说明生成信号无法完全与传感器采集信号相同，还是存在着一定的差异。并且，含有 DCGAN 生成信号的训练集认识率要高于含有 SMOTE 生成信号的训练集。由于实际采集数据过程比较繁琐且采集数据可能受到诸多干扰，可用性不高，使用 DCGAN 模型生成信号扩充训练集来提升认识准确率的方法就十分具有参考意义和使用价值。




图 4.7 传感器采集信号与混合生成信号的比较

4.4 本章小结

本章首先介绍了实验的环境与平台，网络结构设计以及实验数据集的构建。通过设计的CNN分类网络，来检验本文提出的一维DCGAN模型生成信号的效果。与传统方法对比，本文提出方法的DCGAN模型对于认识准确率的提升更高，能提高传感器采集信号训练集认识率3%左右，验证了该方法的有效性。除此之外，对不同数据规模的数据集上展开实验，给出了本方法实现数据增强的有效数据集大小的范围，为现实

工程应用提供了一定的参考。

5 总结与展望

近年来随着中国电力需求容量的不断增长和智能电网概念的发展,亟待通过信息技术方法来解决电力设备的故障信号识别问题。与此同时,深度学习的发展和研究如井喷式爆发,并在多领域内取得了显著的成绩。深度学习需要以数据驱动,且电气设备处于故障状态下的数据比较缺乏,所以,利用生成对抗网络来生成电气设备运行过程中所缺少的故障状态下的振动信号,并利用卷积神经网络针对振动信号完成对电气设备的故障识别具有十分重要的探究价值。

本文首先介绍了电抗器故障诊断的传统方法和基于机器学习的方法,然后对生成对抗网络和卷积神经网络的基本原理进行了阐述,提出利用一维DCGAN生成故障振动信号,扩充训练集;提出利用一维CNN完成电抗器故障信号识别。最终,通过实验验证了本文提出方法的可行性和有效性。本文主要的工作有两个方面:

(1) 针对电抗器振动数据故障信号较少的问题,设计了一种以一维卷积为核心的DCGAN模型,生成故障信号,实现数据增强。以损失函数为切入点,分析了网络有时无法收敛的成因,并给出相应措施指导训练,增强网络的稳定性。针对电抗器故障振动信号识别的问题,以电抗器在正常和故障状态下的仿真振动信号为训练集,设计了针对一维信号的CNN模型,仿真实验表明一维CNN能够有效地识别电抗器中的故障振动信号,并且DCGAN生成信号的方法相比传统方法能更有效地提高CNN识别准确率。

(2) 利用BKD2-140000/800-110型电抗器实采振动信号构建数据集,使用本文中提出的一维DCGAN和一维CNN分别完成对训练集的扩充和分类,设计实验,并与传统数据生成方法对比,能提高传感器采集数据训练集识别率3%左右,验证了本文提出针对高压电抗器故障振动信号识别方法的有效性和故障振动信号生成方法的优越性。

生成对抗网络和卷积神经网络分别在电抗器振动数据生成和故障识别中取得了不错的效果,相关方面的研究也在不断涌现。但是在本文的研究工作中仍然存在着一些不足,还有很多提升的空间。生成对抗网络虽然在数据增强领域有着十分广泛的应用,但是其网络结构对于数据类型的针对性很强,不能很好的迁移到其他数据类型的

增强问题中，泛化能力较弱。此外，还存在着难以训练、生成数据质量不高的问题。这就需要研究者们能够深入GAN的原理，寻找到一个能够很好地衡量不同数据分布之间距离的度量标准，总结出有效的训练策略。在将来的研究中可以从设计新的损失函数角度出发，或者采用训练更稳定的网络结构WGAN、BEGAN等进行训练，增强其泛化能力。最后，本文只对电抗器是否故障做出判断，没有对故障进行进一步的分类，也没有对故障进行定位。电抗器故障类型的进一步细化和故障定位这两方面也是将来进一步研究的重点与方向。

致 谢

时光荏苒，一转眼我在华中科技大学也渡过了快七年的时间，七年前刚踏入校园时的场景还历历在目。随着毕业论文的完成，我的三年研究生生涯也将画上句点。华科明德、厚学、求是、创新的校训始终铭记我心。这七年的校园时光和在校期间得到的锻炼和成长将是我这一生宝贵的财富，让我能以饱满的热情和充足的勇气走入社会，迈向下一个人生阶段。

在此，首先我要向我的导师陈建文副教授表示最衷心的感谢，从论文的选题到开题，再到实验的设计、论文的撰写和修改，都给我提供了无私的帮助和悉心的指导。陈老师在学术上严谨认真的作风和在工作上热情务实的态度深深地感染了我，在生活上的关心和照顾也让我十分感动。同时我也要感谢同一课题组的朱明教授，朱老师对我们严格要求，在我们在遇到瓶颈时都能给出最大限度的指导，为我们指点迷津。我还要感谢徐永健老师、王振老师、蔡博老师，三位老师在我的研究生生涯中也提供了诸多帮助。

其次，我要感谢同门师兄们和我的室友们。感谢已毕业的张裕斌师兄，是你将我领入了学术研究的道路，给我解答学业上疑惑。感谢杨采清师兄和朱帅师弟，你们在我的学习和找工作上都提供了不少帮助。感谢我的室友们，有你们生活上的陪伴，我这三年的时光并不感到孤单。

最后，我要感谢我的父母和家人，你们的支持和理解是我不断奋进、勇往直前的力量源泉。

参考文献

- [1] 岳昊,徐永海,刘颖英,朱永强,肖湘宁.高压并联电抗器非线性模型的分析[J].电力系统及其自动化学报,2011,23(01):39-45.
- [2] 郑涛,赵彦杰.超/特高压可控并联电抗器关键技术综述[J].电力系统自动化,2014,38(07):127-135.
- [3] Kem R , Srisongkram W , Fuangpian P , et al. Electrical Stress Analysis of Switching Transients in 115 kV High Voltage Substation[J]. Applied Mechanics and Materials, 2015, 781:333-336.
- [4] Lotfi A , Faridi M . Design Optimization of Gapped-Core Shunt Reactors[J]. IEEE Transactions on Magnetics, 2012, 48(4):1673-1676.
- [5] Eskandari H , Jafarian P . Effect of interphase magnetic coupling of shunt reactor on transmission-line open-phase overvoltages and neutral reactor optimisation[J]. IET Generation, Transmission & Distribution, 2017, 11(4):1004-1011.
- [6] Min Wook Na,Doyoung Shin,Jae Hyung Park,Jeong Ik Lee,Sung Joong Kim. Indefinite sustainability of passive residual heat removal system of small modular reactor using dry air cooling tower[J]. Nuclear Engineering and Technology,2019.
- [7] 黄斌,徐姗姗,田国稳,阮班义,曾轩.干式空心并联电抗器故障原因分析及防范措施[J].电力电容器与无功补偿,2019,40(04):76-79+87.
- [8] 刘奋霞,刘晔,禹云长,乌江,李继隆,李学成,张耀匀.特高压油浸式铁心并联电抗器内部温度场数值计算与实验研究[J].高压电器,2017,53(01):163-168.
- [9] 谢道伟.油浸式三相电力变压器电磁场及温度场的瞬态仿真分析[D].吉林大学,2015.
- [10] 张科,原会静,郭磊,王立楠.换流站交流滤波电抗器故障分析[J].电力电容器与无功补偿,2013,34(01):74-79.
- [11] 林瑞聪,缪希仁,郭谋发,陈丹,林峰.电抗器潜伏性故障特征及其耦合量分析综述[J].高压电器,2015,51(01):150-155.

- [12]顾哲屹. 干式空心电抗器匝间绝缘材料老化研究[D]. 哈尔滨理工大学, 2017.
- [13]蒋延磊. 串联谐振成套装置对电容性设备进行高电压下介损试验问题的探讨[A]. 灾备技术国家工程实验室、北京邮电大学信息安全中心. 2011 年亚太智能电网与信息工程学术会议论文集[C]. 灾备技术国家工程实验室、北京邮电大学信息安全中心: 中国通信学会青年工作委员会, 2011:4.
- [14]王瀚. 空心电力电抗器绝缘故障在线监测技术研究[D]. 哈尔滨理工大学, 2018.
- [15]Ili D R B , Slater J A , Emanuel A E . A Wireless Differential Protection System for Air-Core Inductors[J]. IEEE Transactions on Power Delivery, 2005, 20(2):579-587.
- [16]Fernando D F G L , Cardoso Junior G . Analytical Technique for Evaluating Stray Capacitances in Multiconductor Systems: Single-Layer Air-Core Inductors[J]. IEEE Transactions on Power Electronics, 2017:1-1.
- [17]巨建成. 500kV 并联电抗器色谱分析异常及故障处理[J]. 华北电力技术, 2016(04):33-37.
- [18]陈宏刚. 750kV 可控高抗油色谱数据异常情况研究[D]. 兰州大学, 2013.
- [19]黄祖荣, 陈玮光, 王睿宣. 铁芯多点接地致 35kV 并联电抗器过热故障分析[J]. 电力安全技术, 2018,20(07):25-28.
- [20]田肖飞, 孙文星, 杨贤, 马志钦, 欧小波. 油浸式并联铁心电抗器缺陷分析及整改措施[J]. 广东电力, 2019,32(02):144-151.
- [21]孙帆, 张勇, 徐路强, 范旭华. 一台 750kV 高压电抗器局部放电故障分析[J]. 高压电器, 2015,51(03):135-139.
- [22]武奇. 基于 Ansoft 的空心电抗器磁屏蔽研究[J]. 电气工程学报, 2019,14(02):61-65.
- [23]吴敏辉. 基于场路耦合的磁阀式可控电抗器损耗特性分析[J]. 电力电容器与无功补偿, 2019,40(03):64-69+78.
- [24]戴奇奇. 特高压油浸式空心电抗器磁场及温度场特性分析[D]. 华中科技大学, 2019.
- [25]Yuan F T , Yuan Z , Liu J X , et al. Research on temperature field simulation of dry type

- air core reactor[C]// 2017 20th International Conference on Electrical Machines and Systems (ICEMS). IEEE, 2017.
- [26]Cao J , Chen T , Jiang Z , et al. Coupling calculation of temperature field for dry-type smoothing reactor[C]// International Conference on Electrical Machines & Systems. IEEE, 2014.
- [27]Xiuke Y X Y , Zhongbin D Z D , Cunzhan Y C Y , et al. Research on magnetic field and temperature field of air core power reactor[M]. 2011.
- [28]Hongyan N , Chaohai Z , Zheyi G , et al. The Research on Electrical Aging Characteristics of Turn-to-Turn Insulation of Dry-Type Air Core Reactor under Partial Discharge[J]. Transactions of China Electrotechnical Society, 2018.
- [29]Zhang Y J , Qin W N , Wu G L , et al. Analysis of temperature rise in reactors using coupled multi-physics simulations[C]// 2013 IEEE International Conference on Applied Superconductivity and Electromagnetic Devices (ASEMD). IEEE, 2013.
- [30]张琪. 空心电力电抗器绝缘故障在线监测[J]. 电力电容器与无功补偿, 2019,40(05):116-121+127.
- [31]Song M , Ren L , Cao K N , et al. Design and Test of Saturable Reactor[J]. Advanced Materials Research, 2012, 516-517:1342-1347.
- [32]张鹏宁, 李琳, 聂京凯, 樊超, 程志光. 考虑铁心磁致伸缩与绕组受力的高压并联电抗器振动研究[J]. 电工技术学报, 2018,33(13):3130-3139.
- [33]潘信诚, 马宏忠, 陈明, 郝宝欣, 陈轩, 谭风雷. 基于 CRP 和 RQA 的高压并联电抗器振动信号分析[J]. 大电机技术, 2019(03):62-67.
- [34]赵文清, 王强, 牛东晓. 基于贝叶斯网络的电抗器健康诊断[J]. 电力自动化设备, 2013,33(01):40-43.
- [35]Richardson Z J , Fitch J , Tang W H , et al. A Probabilistic Classifier for Transformer Dissolved Gas Analysis With a Particle Swarm Optimizer[J]. IEEE Transactions on Power Delivery, 2008, 23(2):751-759.
- [36]吴金利, 马宏忠, 吴书煜, 侯鹏飞. 基于振动信号的高压并联电抗器故障诊断方法与

- 监测系统研制[J].电测与仪表,2020,57(01):113-120.
- [37]赵春明,张雷,敖明,李鹏,许永盛,李立学.基于 ANN 的大型干式电抗器的超高频局放检测技术[J].变压器,2017,54(10):54-57.
- [38]任飞凯. 基于卷积神经网络人脸识别研究与实现[D]. 南京邮电大学, 2019.
- [39]章琳,袁非牛,张文睿,曾夏玲.全卷积神经网络研究综述[J].计算机工程与应用,2020,56(01):25-37.
- [40]李超. 基于卷积神经网络的人体行为分析与步态识别研究[D].浙江大学,2019.
- [41]Léculun Y, Bottou L, Bengio Y, et al. Gradient-based learning applied to document recognition[J]. Proceedings of the IEEE, 1998, 86(11):2278-2324.
- [42]Goodfellow, Ian, Pouget-Abadie, Jean, Mirza, Mehdi, Xu, Bing, Warde-Farley, David, Ozair, Sherjil, Courville, Aaron, and Bengio, Yoshua. Generative adversarial nets[C]. Advances in Neural Information Processing Systems, pp. 2672–2680, 2014.
- [43]Arjovsky M, Chintala S, Bottou L. Wasserstein gan[J]. arXiv preprint arXiv:1701.07875, 2017.
- [44]Berthelot D, Schumm T, Metz L. BEGAN: Boundary Equilibrium Generative Adversarial Networks[J]. arXiv:1703.10717, 2017.
- [45]Mirza M, Osindero S. Conditional generative adversarial nets[J]. arXiv preprint arXiv:1411.1784, 2014.
- [46]Radford A, Metz L, Chintala S. Unsupervised representation learning with deep convolutional generative adversarial networks[J]. arXiv preprint arXiv:1511.06434, 2015.
- [47]Zhu J Y , Park T , Isola P , et al. Unpaired Image-to-Image Translation using Cycle-Consistent Adversarial Networks[J]. 2017.
- [48]Chen X , Duan Y , Houthoof R , et al. InfoGAN: Interpretable Representation Learning by Information Maximizing Generative Adversarial Nets[J]. 2016.
- [49]Ledig C , Theis L , Huszar F , et al. Photo-Realistic Single Image Super-Resolution Using a Generative Adversarial Network[J]. 2016.

- [50]王坤峰, 苟超, 段艳杰, 林懿伦, 郑心湖, 王飞跃. 生成式对抗网络GAN的研究进展与展望[J].自动化学报,2017,43(03):321-332.
- [51]周兵, 王延召, 胡静竹, 倪园, 万保权, 刘震寰. 并联电抗器振动特性及声功率级计算[J]. 高电压技术,2019,45(11):3685-3692.
- [52]肖艳梅. 计及信息多源化条件下的电力系统故障诊断模型与体系的研究[D]. 华南理工大学,2015.
- [53]魏旭, 吴书煜, 姜宁, 陈轩, 谭风雷, 马宏忠, 赵若好, 潘信诚. 高压电抗器振动特性及实验分析[J].高压电器,2019,55(11):66-73.
- [54]周兵,王延召,胡静竹,倪园,万保权,刘震寰.并联电抗器振动特性及声功率级计算[J]. 高电压技术,2019,45(11):3685-3692.
- [55]Kingma D P, Ba J. Adam: A method for stochastic optimization[J]. arXiv preprint arXiv:1412.6980, 2014.
- [56]信息论[M]. 电子工业出版社 , 傅祖芸, 2007
- [57]Yu D, Yao K, Su H, et al. KL-divergence regularized deep neural network adaptation for improved large vocabulary speech recognition[C]//2013 IEEE International Conference on Acoustics, Speech and Signal Processing. IEEE, 2013: 7893-7897.